



**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»**

ИТОГОВАЯ АТТЕСТАЦИОННАЯ РАБОТА

по дополнительной профессиональной программе профессиональной переподготовки

«Организация процесса разработки компьютерного программного обеспечения»

на тему: «Очистка космических снимков от облаков»

№	Фамилия, Имя, Отчество (полностью)	Группа по ООП	Группа по ДПП ПП	Подпись
1	Иванов Дмитрий Евгеньевич	М8О-305Б-22		
2	Сергеев Георгий Олегович	М8О-305Б-22		
3	Аристов Никита Леонидович	М8О-305Б-22		
4	Шанаурина Анна Игоревна	М8О-305Б-22		
5	Машковцев Никита Денисович	М8О-305Б-22		

Руководитель итоговой аттестационной работы:

Рецензент итоговой аттестационной работы:

Присваиваемая квалификация

«Программист»

Москва 2024

СПИСОК ИСПОЛНИТЕЛЕЙ

№	Фамилия, Имя, Отчество	Название и номер раздела
1	Иванов Дмитрий Евгеньевич	1. Анализ и постановка задачи разработки IT-решения: направления и цель проекта 2. Описание модели SpA-GAN
2	Сергеев Георгий Олегович	3. Архитектура модели SpA-GAN 5. Преимущества модели SpA-GAN
3	Аристов Никита Леонидович	4. Обучение модели SpA-GAN 6. Сравнительный анализ с другими моделями
4	Шанаурина Анна Игоревна	6. Сравнительный анализ с другими моделями 8. Примеры работы модели
5	Машковцев Никита Денисович	4. Обучение модели SpA-GAN 7. Метрики для оценки качества изображения

Реферат

Итоговая аттестационная работа состоит из 131 страниц, 18 рисунков, 20 таблиц, 37 использованных источников, четырех приложений. МАШИННОЕ ОБУЧЕНИЕ, ГЛУБИННОЕ ОБУЧЕНИЕ, НЕЙРОННЫЕ СЕТИ, МОДЕЛИ, ГЕНЕРАТИВНЫЕ НЕЙРОННЫЕ СЕТИ, СВЕРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ, ГЕНЕРАТОР, ДИСКРИМИНАТОР, ФУНКЦИЯ ПОТЕРЬ, АНАЛИЗ ДАННЫХ. Итоговая аттестационная работа выполнена в формате IT-проекта на тему «Алгоритм очистки космических снимков от облаков» и сконцентрирована на обработке изображений для удаления шумов, которые мешают исследовать территорию, изображенную на космическом снимке.

Объектом разработки в данной работе является программа, позволяющая очистить космические снимки от облаков.

Цель работы – разработать и эффективный алгоритм автоматической очистки космических снимков от облачности, который позволит улучшить качество и доступность данных дистанционного зондирования Земли. Это обеспечит более точный анализ поверхности планеты для различных применений, включая мониторинг окружающей среды, сельское хозяйство, урбанистическое планирование и оперативное реагирование на чрезвычайные ситуации.

Работа выполнялась проектной командой в соответствии с методологией проектного управления в IT-индустрии.

Оглавление

Введение.....	5
1. Анализ и постановка задачи разработки IT-решения: направления и цель проекта.....	7
1.1 Актуальность разработки IT-решения.....	7
1.2 Критический обзор существующих подходов к решению задачи	9
1.3 Техническое задание	17
2. Описание модели SpA-GAN.....	20
2.1 Обоснование выбора данной модели.....	20
2.2 Характеристика модели	27
2.3 Цели и задачи модели.....	28
2.4 Ключевые особенности модели	30
3. Архитектура модели SpA-GAN	34
3.1 Общая структура	34
3.2 Архитектура генератора	35
3.3 Архитектура дискриминатора	38
3.4 Состязательное обучение	39
3.5 Особенности реализации.....	41
3.6 Технические аспекты	42
4. Обучение модели SpA-GAN	44
4.1 Общий обзор процесса работы.....	44
4.2 Обработка входного изображения	45
4.3 Процесс обучения	48
4.4 Роль механизма пространственного внимания в процессе работы..	51
4.5 Обработка данных внутри модели.....	52

4.6 Взаимодействие генератора и дискриминатора	53
4.7 Завершение обучения модели	54
4.8 Применение обученной модели	55
5. Преимущества модели SpA-GAN	56
6. Сравнительный анализ с другими моделями.....	60
7. Метрики для оценки качества изображения.....	69
7.1 Полноценные метрики с опорными данными	69
7.2 Метрики без опорных данных.....	72
7.3 Перцептуальные метрики	73
7.4 Задачно-специфичные метрики.....	75
7.5 Субъективно-визуальная оценка.....	76
7.6 Сравнительный анализ метрик.....	78
8. Примеры работы модели.....	79
Заключение	80
Литература	83
Приложение А	86
Ссылка и QR-код на проект Github	86
Приложение Б	86
Полный код программы.....	86

Введение

Космические снимки, получаемые с помощью современных спутников дистанционного зондирования Земли, являются одним из ключевых инструментов для изучения нашей планеты и ее окружающей среды. Они

предоставляют ценную информацию о состоянии земной поверхности, атмосферы, океанов и льдов, позволяя ученым и специалистам в различных областях проводить детальный анализ природных и антропогенных процессов. Спутниковые изображения находят широкое применение в метеорологии для прогнозирования погоды и изучения климатических изменений, в сельском хозяйстве для оценки состояния посевов и прогнозирования урожайности, в картографии для обновления географических карт и навигационных систем, в экологическом мониторинге для отслеживания состояния экосистем и выявления зон загрязнения, а также во многих других сферах человеческой деятельности.

Однако эффективное использование космических снимков часто затрудняется наличием облачного покрова, который может полностью или частично скрывать интересующие объекты на земной поверхности. Облака, являясь неотъемлемой частью атмосферных процессов, могут существенно уменьшать информативность спутниковых изображений. Они создают проблемы при визуальном анализе данных, затрудняют автоматическую обработку изображений и могут приводить к искажению результатов при оценке различных параметров земной поверхности. Особенно остро эта проблема ощущается в тропических и умеренных широтах, где облачность является частым явлением и может присутствовать значительную часть времени.

В связи с этим возникает необходимость в разработке эффективных методов и алгоритмов, позволяющих автоматически обнаруживать и удалять облачность с космических снимков, а также восстанавливать скрытую под облаками информацию. Решение этой задачи имеет большое практическое значение, так как позволяет существенно повысить качество и достоверность данных дистанционного зондирования, расширить возможности их использования для мониторинга природных ресурсов, управления

территорией, исследования климатических изменений и решения многих других актуальных задач.

В последние годы в области обработки спутниковых изображений наметился значительный прогресс, связанный с развитием методов машинного обучения, глубоких нейронных сетей и других современных технологий. Появились новые подходы к решению задач сегментации изображений, классификации объектов, восстановления недостающих данных. Однако проблема очистки космических снимков от облаков остается по-прежнему актуальной и требует дальнейшего исследования и совершенствования методов обработки.

1. Анализ и постановка задачи разработки IT-решения: направления и цель проекта

1.1 Актуальность разработки IT-решения

Актуальность данной научной работы обусловлена несколькими важными факторами. Во-первых, глобальные климатические изменения, наблюдаемые в последние десятилетия, приводят к увеличению частоты экстремальных погодных явлений, изменению режимов осадков и облачности. Это повышает необходимость в регулярном и точном мониторинге земной поверхности и атмосферных процессов с помощью спутниковых данных. Облачность, присутствующая на значительной части космических снимков, затрудняет этот мониторинг и снижает оперативность и точность получаемой информации.

Во-вторых, современные задачи природопользования, урбанистики, сельского хозяйства и экологии требуют высокой пространственной и временной разрешающей способности данных дистанционного зондирования.

Для эффективного управления ресурсами и принятия обоснованных решений необходимо иметь доступ к чистым и качественным изображениям земной поверхности. Наличие облачного покрова существенно ограничивает возможности использования спутниковых данных в этих сферах и может приводить к неточным оценкам и прогнозам.

В-третьих, развитие технологий искусственного интеллекта и обработки больших данных открывает новые перспективы для решения сложных задач, связанных с анализом спутниковых изображений. Однако для эффективного применения этих технологий необходимо иметь качественные и очищенные от помех данные. Создание алгоритмов, способных автоматически обнаруживать и удалять облачность, а также восстанавливать подлежащую информацию, является важным шагом в этом направлении.

Существующие методы обработки спутниковых данных часто не позволяют полностью решить проблему облачности. Многие из них основаны на статистических или пороговых подходах, которые могут быть недостаточно точными или универсальными. Другие методы требуют значительных вычислительных ресурсов или предварительной обучающей выборки, что затрудняет их применение в оперативных условиях или на больших объемах данных.

Таким образом, разработка нового эффективного алгоритма очистки космических снимков от облаков является актуальной научной задачей, имеющей практическое значение для многих областей. Такой алгоритм должен обеспечивать высокую точность обнаружения облачного покрова, минимизировать искажения при восстановлении подлежащей информации, быть устойчивым к различным условиям съемки и типам спутниковых данных, а также обладать приемлемой вычислительной сложностью для практического применения.

Решение этой задачи позволит существенно повысить качество данных дистанционного зондирования Земли, расширить возможности их использования в различных областях науки и техники, улучшить точность и надежность принимаемых управленческих решений. Кроме того, результаты данного исследования могут способствовать дальнейшему развитию методов обработки изображений, машинного обучения и искусственного интеллекта, стимулировать появление новых технологий и подходов в области анализа спутниковых данных.

В условиях растущей потребности общества в оперативной и достоверной информации о состоянии окружающей среды, успешное решение проблемы очистки космических снимков от облачности имеет не только научное, но и большое социально-экономическое значение. Это позволит более эффективно реагировать на глобальные вызовы современности, связанные с изменением климата, обеспечением продовольственной безопасности, управлением природными ресурсами и охраной окружающей среды.

1.2 Критический обзор существующих подходов к решению задачи

Традиционные методы обнаружения и удаления облачности

1. Спектральные пороговые методы

Описание метода: Основываются на использовании фиксированных пороговых значений отражательной способности в различных спектральных диапазонах для классификации пикселей как облачных или безоблачных. Облака обычно обладают высокой отражательной способностью в видимом и

ближнем инфракрасном диапазонах и низкой в тепловом инфракрасном диапазоне.

Преимущества:

- Простота реализации.
- Невысокие вычислительные затраты.

Недостатки:

- Ограниченная точность из-за вариативности свойств облаков.
- Неэффективность при наличии тонких или полупрозрачных облаков.
- Зависимость от условий освещенности и атмосферы.

2. Методы индексных соотношений

Описание метода: Использование спектральных индексов, таких как нормализованный дифференциальный водный индекс (NDWI) или индекс яркости, для дифференциации облаков от других объектов на поверхности Земли.

Преимущества:

- Улучшают разделение облаков и подстилающей поверхности в некоторых условиях.
- Могут компенсировать влияние вариаций освещенности.

Недостатки:

- Могут неверно классифицировать яркие поверхности (снег, песок) как облака.
- Зависимость от корректной калибровки и атмосферной коррекции данных.

Мультивременные и мультиспектральные методы

1. Методы композитных изображений

Описание метода: Создание композитных изображений путем комбинирования нескольких снимков одного района, сделанных в разное время, для получения полной картины без облаков.

Преимущества:

- Позволяют восстановить области, постоянно закрытые облаками на отдельных снимках.
- Улучшают временную и пространственную непрерывность данных.

Недостатки:

- Требуют наличия серии снимков за определенный период.
- Неэффективны для динамически изменяющихся объектов.
- Возможны артефакты из-за сезонных изменений или различий в углах съемки.

2. Использование данных разных сенсоров

Описание метода: Комбинация данных от оптических сенсоров с данными активных сенсоров, таких как радиолокационные системы (SAR), которые менее подвержены влиянию облачности.

Преимущества:

- Обеспечивают дополнительную информацию о подстилающей поверхности.
- Повышают надежность классификации и картирования.

Недостатки:

- Сложность совмещения данных с разным пространственным разрешением и характеристиками.
- Требуют сложных методов интеграции данных.
- Ограниченная доступность многоспектральных и многотипных данных.

Статистические и моделируемые методы

1. Интерполяция и экстраполяция данных

Описание метода: Пространственно-временная интерполяция недостающих пикселей на основе данных окружающих областей или предыдущих моментов времени.

Преимущества:

- Простота реализации.
- Эффективность для небольших облачных участков.

Недостатки:

- Не способны восстановить уникальные или сложные объекты под облачностью.
- Могут вводить значительные ошибки в случае крупных и сложных по форме облачных областей.

1. Математическое моделирование и анализ главных компонент (РСА)

Описание метода: Использование статистических моделей для выделения и удаления облачной компоненты из данных, анализируя вариации в спектральных характеристиках.

Преимущества:

- Могут выявлять скрытые паттерны в данных.

- Позволяют уменьшить размерность данных и улучшить обработку.

Недостатки:

- Затруднения в интерпретации результатов.
- Необходимо предположение о линейности данных.
- Возможность потери важных деталей при агрессивном сокращении размерности.

Методы на основе машинного обучения

1. Классификация с использованием традиционных алгоритмов

Описание метода: Применение алгоритмов машинного обучения, таких как метод опорных векторов (SVM), деревья решений, k-ближайших соседей (k-NN), для классификации пикселей как облачных или безоблачных на основе их спектральных и текстурных признаков.

Преимущества:

- Более высокая точность по сравнению с пороговыми методами.
- Способность учитывать нелинейные зависимости между признаками.

Недостатки:

- Требуют большого объема размеченных данных для обучения.
- Возможность переобучения и снижение точности на новых данных.
- Чувствительность к выбору признаков и параметров модели.

2. Глубокие нейронные сети (Deep Learning)

Описание метода: Использование сверточных нейронных сетей (CNN) и других архитектур глубокого обучения для автоматического выделения признаков и классификации пикселей.

Преимущества:

- Высокая способность к автоматическому выделению сложных и иерархических признаков.
- Отличная производительность в задачах классификации и сегментации изображений.
- Возможность обработки больших объемов данных.

Недостатки:

- Требуют огромных объемов размеченных данных для обучения.
- Высокие вычислительные затраты (требуют GPU и других мощных ресурсов).
- Риск переобучения и необходимость регуляризации.
- Трудности в интерпретации внутренних представлений модели.

3. Генеративно-состязательные сети (GANs) для восстановления изображений

Описание метода: Использование GANs для синтеза недостающих областей изображения на основе обучения генератора и дискриминатора, где генератор пытается создать реалистичные данные, а дискриминатор оценивает их достоверность.

Преимущества:

- Могут генерировать высококачественные и реалистичные изображения.
- Способны восстанавливать сложные текстуры и структуры.

Недостатки:

- Сложность и нестабильность процесса обучения.
- Возможность генерирования недостоверной информации (артефактов).
- Этические и практические вопросы, связанные с синтетической генерацией данных вместо реальных измерений.

Альтернативные подходы

1. Методы на основе времени пролета и лазерного сканирования

Описание метода: Использование активных систем, таких как лидары, для получения детальной информации о поверхности, которая не зависит от освещенности и облачности.

Преимущества:

- Высокая точность и детализация данных о рельефе и объектах.
- Независимость от погодных условий.

Недостатки:

- Ограниченная доступность и высокая стоимость данных.
- Невозможность получения спектральной информации, доступной в оптическом диапазоне.

2. Квантовые и гиперспектральные методы

Описание метода: Исследование новых физических принципов и использования гиперспектральных данных для более точного различения облаков и подстилающей поверхности.

Преимущества:

- Потенциально более высокая точность благодаря использованию дополнительной спектральной информации.

- Возможности выявления уникальных спектральных подписей различных объектов.

Недостатки:

- Техническая сложность и высокая стоимость получения гиперспектральных данных.

- Большие объемы данных и сложности в их обработке и хранении.

Традиционные методы, основанные на пороговом значении и простых спектральных индексах, являются быстрыми и простыми, но страдают от низкой точности в сложных условиях, таких как тонкие облака или схожие по спектру объекты на поверхности Земли. Мультивременные и мультиспектральные методы улучшают качество за счет использования дополнительной информации, но имеют ограничения, связанные с доступностью данных и временными аспектами.

Методы машинного обучения предлагают значительные улучшения в точности и адаптивности, но требуют большого количества качественных данных для обучения и значительных вычислительных ресурсов. Кроме того, риск переобучения и сложность интерпретации результатов могут ограничивать их практическое применение.

Глубокие нейронные сети и GANs особенно перспективны, но их применение в реальных условиях затруднено из-за необходимости больших размеченных датасетов и сложности обучения. Также существует риск, что сгенерированные данные не будут соответствовать реальной ситуации на местности, что может привести к ошибочным выводам и решениям.

Альтернативные методы, такие как использование лидаров или гиперспектральных данных, предлагают новые возможности, но ограничены техническими и экономическими факторами.

В целом, ни один из существующих методов не является универсальным решением проблемы облачности на космических снимках. Каждый подход имеет свои преимущества и ограничения, и выбор конкретного метода зависит от целей исследования, доступных ресурсов и условий съемки.

Перспективным направлением является комбинирование различных методов для компенсации недостатков каждого из них. Например, интеграция традиционных спектральных методов с алгоритмами машинного обучения может улучшить точность и устойчивость классификации. Также актуально развитие методов переноса обучения и использования синтетических данных для уменьшения зависимости от большого количества размеченных данных.

Необходимы дальнейшие исследования в области разработки эффективных, устойчивых и интерпретируемых методов обработки космических снимков, способных работать в различных условиях и обеспечивать высокое качество получаемых данных. Это позволит значительно повысить эффективность использования данных дистанционного зондирования Земли и расширить возможности их применения в науке и практике.

1.3 Техническое задание

Цель проекта - создать программное обеспечение для автоматического обнаружения и удаления облачности на космических снимках, улучшая качество данных дистанционного зондирования Земли для различных отраслей.

Основные задачи

- Обнаружение облачности:
 - Разработать алгоритм, автоматически определяющий облачные области на спутниковых изображениях с высокой точностью.
- Удаление облачности:
 - Реализовать метод удаления облачных областей и восстановления скрытых участков посредством реконструкции или замещения данными из других источников.
- Интеграция и формат данных:
 - Обеспечить поддержку основных форматов космических снимков (GeoTIFF, JPEG2000, HDF5 и др.).
 - Обеспечить возможность интеграции с существующими геоинформационными системами и инструментами.

Требования к системе

- Функциональные требования:
 - Автоматическое обнаружение и маркировка облачных областей.
 - Удаление облачности и восстановление изображений с минимальными искажениями.
 - Поддержка пакетной обработки нескольких снимков.
- Нефункциональные требования:
 - Высокая производительность и оптимизация для стандартного оборудования.
 - Возможность использования параллельных вычислений и GPU.
 - Надежность и устойчивость к ошибкам.

Технические требования

- Технологии:
 - Язык программирования: Python.
 - Библиотеки: OpenCV, GDAL, TensorFlow или PyTorch для машинного обучения.
- Алгоритмы и методы:

- Использование глубоких нейронных сетей (CNN) для сегментации облачности.

- Методы восстановления изображений (интерполяция, генеративные модели).

- Среда выполнения:

- Совместимость с операционными системами Windows и Linux.

- Поддержка исполнения на CPU и GPU.

Этапы выполнения работ

1. Планирование и анализ требований.

2. Исследование и выбор оптимальных методов обнаружения и удаления облачности.

3. Разработка и тестирование алгоритмов.

4. Создание прототипа системы и пользовательского интерфейса.

5. Тестирование на реальных данных и оптимизация.

6. Подготовка технической документации и руководства пользователя.

Критерии приемки работ

- Функциональность:

- Система успешно обнаруживает и удаляет облачность на тестовых снимках.

- Качество обработки:

- Точность обнаружения облачности не менее 90% по F1-мере.

- Восстановленные области соответствуют требованиям по качеству.

- Производительность:

- Время обработки соответствует заданным показателям.

- Надежность:

- Система устойчива к ошибкам и исключительным ситуациям.

2. Описание модели SpA-GAN

2.1 Обоснование выбора данной модели

Модель SpA-GAN (Spatial Attention Generative Adversarial Network) была выбрана для задачи очистки космических снимков от облаков по нескольким весомым причинам, связанным с ее архитектурными особенностями, способностью эффективно обрабатывать сложные данные и превосходством над другими методами. Рассмотрим эти причины более подробно:

1. Механизм пространственного внимания:

- Фокусировка на важных областях изображения:
 - SpA-GAN интегрирует механизм пространственного внимания в свою архитектуру, что позволяет модели автоматически идентифицировать и сосредотачиваться на облачных областях изображения, требующих восстановления.
 - Этот механизм работает путем оценки весомости различных частей изображения и выделения тех районов, где присутствуют облака, используя особенности таких областей, как яркость, текстура и цветовые характеристики.
 - Благодаря этому модель не растрчивает ресурсы на обработку уже корректных частей изображения, фокусируясь на проблемных зонах и улучшая общую эффективность процесса восстановления.
- Сохранение пространственного контекста и структурной целостности:
 - Механизм внимания обеспечивает учет пространственных связей между различными участками изображения, что особенно важно при обработке спутниковых снимков с их сложными ландшафтами и объектами.

- Это позволяет модели восстанавливать скрытые под облаками детали, сохраняя при этом естественные переходы и структурное сходство с окружающими областями, предотвращая появление артефактов или неоднородностей.

2. Улучшенное качество восстановления благодаря генеративно-сопоставительной архитектуре:

- Генеративно-сопоставительная сеть (GAN):

- SpA-GAN построена на принципе генеративно-сопоставительных сетей, где генератор и дискриминатор обучаются в непрерывном взаимодействии.

- Генератор стремится создать реалистичное изображение без облаков, имитируя текстуры и детали, скрытые под облаками.

- Дискриминатор пытается различить реальные изображения без облаков и созданные генератором, что стимулирует генератор улучшать качество синтезированных областей.

- Создание естественных текстур и соответствие контексту:

- GAN-архитектуры, и в частности SpA-GAN, способны генерировать высококачественные изображения с реалистичными деталями.

- В результате восстановленные области органично вписываются в контекст изображения, соответствуя цветовой гамме, текстурам и структурным особенностям окружающих областей.

- Это особенно важно для прикладных задач, где качество и достоверность данных имеют ключевое значение, например, в сельском хозяйстве, экологии или картографии.

3. Эффективная обработка сложных структур и объектов:

- Разнообразие географических и антропогенных объектов:

- Спутниковые снимки содержат широкий спектр объектов: от природных ландшафтов (горы, леса, водоемы) до городских построек и инфраструктур.

- Способность SpA-GAN учитывать пространственные взаимосвязи и контекст позволяет ей эффективно восстанавливать эти разнообразные структуры, обеспечивая целостность и точность изображений.

- Модель может различать и правильно восстанавливать мелкие детали, такие как дороги, реки или отдельные здания, что особенно важно для точного анализа земной поверхности.

- Обработка тонких облачных структур и теней:

- Облака могут быть разной плотности и прозрачности, включая полупрозрачные слои и тонкие облачные образования, а также тени от облаков, которые затрудняют анализ изображения.

- SpA-GAN обучена распознавать и эффективно устранять такие сложные элементы, что позволяет получить чистое изображение с минимальными искажениями и потерями информации.

4. Адаптивность к различным типам данных и условиям съемки:

- Гибкость по отношению к разнообразию спутниковых данных:

- Спутниковые изображения могут сильно различаться по своим параметрам: спектральным характеристикам, разрешению, углу съемки, временам года и погодным условиям.

- SpA-GAN демонстрирует устойчивость к этим вариациям благодаря своей способности обучаться на большом объеме разнородных данных и извлекать обобщенные признаки, релевантные для задачи удаления облаков.

- Это позволяет применять модель к данным с различных спутников и сенсоров, что расширяет ее практическое применение.

- Работа с мультиспектральными и гиперспектральными данными:

- Современные спутники предоставляют изображения в различных спектральных диапазонах, включая инфракрасный и ультрафиолетовый, что важно для различных аналитических задач.

- SpA-GAN может быть адаптирована для обработки мультиспектральных данных, учитывая спектральные особенности облаков и подлежащей поверхности, что повышает точность обнаружения и удаления облачности.

5. Преимущества перед традиционными методами обработки изображений:

- Ограничения детерминированных и эмпирических подходов:

- Традиционные методы, как правило, основаны на фиксированных пороговых значениях или простых математических моделях, которые не учитывают сложность и вариативность реальных данных.

- Такие методы могут дать ложные срабатывания или пропустить облачные участки, особенно в условиях изменяющегося освещения или при наличии сходных по характеристикам объектов.

- Преимущества глубокого обучения и SpA-GAN:

- Глубокие нейронные сети способны автоматически извлекать сложные и нелинейные зависимости из данных, что позволяет им адаптироваться к различным условиям и особенностям изображений.

- SpA-GAN, в частности, сочетает в себе преимущества GAN и механизмов внимания, что обеспечивают высокую точность и надежность.

- Снижение артефактов и повышение качества восстановления:

- В отличие от методов, основанных на интерполяции или замещении, которые могут вводить искажения или неестественные элементы, SpA-GAN генерирует восстановленные области, максимально схожие с реальными данными.

- Это достигается за счет обучения на больших наборах данных и способности модели учиться на реальных примерах, что существенно снижает вероятность появления артефактов.

6. Доказанная эффективность и результаты исследований:

- Экспериментальные подтверждения превосходства SpA-GAN:

- В ряде научных работ и исследований было показано, что SpA-GAN превосходит другие методы по ключевым метрикам качества.

- Например, по метрикам PSNR и SSIM модель демонстрирует более высокие показатели, что свидетельствует о лучшем сохранении деталей и структурного сходства с эталонными изображениями.

- Практические применения и кейсы использования:

- Модель успешно применяется в реальных проектах, связанных с мониторингом изменений земной поверхности, оценки ущерба от стихийных бедствий, управления сельскохозяйственными угодьями и другими областями.

- Отзывы пользователей и специалистов подтверждают эффективность SpA-GAN в улучшении качества данных и принятии более обоснованных решений на их основе.

7. Возможность дальнейшего развития и адаптации:

- Модульность и расширяемость архитектуры:

- Архитектура SpA-GAN позволяет интегрировать дополнительные компоненты или модифицировать существующие для решения специфических задач.

- Например, можно добавить механизмы временного внимания для обработки последовательностей изображений и учета динамики изменений во времени.

- Интеграция с другими технологиями и методами:

- SpA-GAN может быть объединена с другими подходами глубокого обучения, такими как сегментация или детекция объектов, для создания комплексных систем анализа спутниковых данных.

- Это открывает возможности для разработки многофункциональных платформ, способных решать широкий спектр задач в сфере дистанционного зондирования и геоинформационных систем.

Выбор модели SpA-GAN для задачи очистки космических снимков от облаков обусловлен ее передовыми техническими характеристиками и доказанной эффективностью в решении этой сложной проблемы. Ключевые преимущества модели включают:

- Способность эффективно идентифицировать и восстанавливать облачные области благодаря механизму пространственного внимания, что обеспечивает фокусировку на важных зонах и сохранение контекстной информации.

- Высокое качество восстановленных изображений за счет генеративно-состязательной архитектуры, позволяющей генерировать реалистичные детали и текстуры, соответствующие окружающим областям.

- Адаптивность к различным типам данных и условиям съемки, что делает модель универсальной и применимой к широкому спектру задач и данных с разных спутников.

- Превосходство над традиционными методами, проявляющееся в более высокой точности, надежности и способности справляться со сложными случаями, где детерминированные алгоритмы могут быть неэффективны.

- Доказанная эффективность и возможность дальнейшего развития, подкрепленная исследованиями и практическими кейсами, что делает SpA-GAN перспективным инструментом для долгосрочного использования.

В современном мире, где спутниковые данные играют все более важную роль в различных сферах, от мониторинга климата до планирования городов, наличие качественных и точных изображений становится критически важным. Облака, будучи природным явлением, часто выступают препятствием для получения чистых данных, особенно в регионах с высокой облачностью. Применение моделей, таких как SpA-GAN, позволяет преодолеть этот барьер, обеспечивая доступ к необходимой информации и повышая эффективность и точность последующих аналитических процессов.

Практическая значимость использования SpA-GAN заключается в следующем:

- Улучшение качества данных для аналитики и принятия решений: Чистые изображения без облаков позволяют проводить более точный анализ, что важно для правительственных организаций, бизнеса и научного сообщества.
- Сокращение затрат и времени на обработку данных: Автоматизация процесса удаления облаков экономит ресурсы, которые могут быть направлены на другие важные задачи.
- Расширение возможностей мониторинга среды и реагирования на чрезвычайные ситуации: Быстрое получение чистых спутниковых изображений позволяет оперативнее реагировать на природные катастрофы, такие как наводнения или лесные пожары.

В перспективе, продолжающееся развитие и усовершенствование моделей на базе SpA-GAN откроет новые горизонты в области обработки и анализа спутниковых данных. Возможности интеграции с другими технологиями и адаптации к новым задачам делают эту модель ключевым инструментом в арсенале современных технологий дистанционного зондирования.

Таким образом, выбор SpA-GAN является обоснованным и стратегически важным решением для задачи очистки космических снимков от облаков, обеспечивая высокое качество данных, необходимое для точного и эффективного анализа Земли из космоса.

2.2 Характеристика модели

SpA-GAN (Spatial Attention Generative Adversarial Network) — это передовая модель глубокого обучения, созданная для решения одной из наиболее сложных проблем в области дистанционного зондирования Земли: удаления облачности с оптических спутниковых изображений. Облачность часто препятствует получению четких и информативных снимков поверхности Земли, что ограничивает возможности анализа и использования данных в различных отраслях.

Название модели расшифровывается как «Генеративная Состязательная Сеть с Пространственным Вниманием». Она сочетает в себе мощь генеративно-состязательных сетей (GAN) и механизмов пространственного внимания, что позволяет ей эффективно восстанавливать скрытую под облаками информацию с высокой степенью точности и детализации.

Генеративно-Состязательные Сети (GAN):

GAN — это класс моделей глубокого обучения, состоящих из двух нейронных сетей:

- Генератор: пытается создавать данные (в данном случае изображения), которые максимально похожи на реальные.
- Дискриминатор: стремится отличить реальные данные от сгенерированных.

Обе сети обучаются одновременно в процессе, который можно представить как игру с нулевой суммой: генератор пытается обмануть дискриминатор, а дискриминатор учится лучше распознавать фальшивые данные. В результате этого состязания генератор постепенно улучшает качество создаваемых данных.

Механизм Пространственного Внимания:

Механизмы внимания в нейронных сетях позволяют моделям фокусироваться на наиболее важных частях входных данных при выполнении задач. В случае пространственного внимания модель может выделять и обрабатывать значимые области в изображении. Это особенно полезно для задач, где важно учитывать пространственные взаимосвязи и особенности определенных регионов изображения.

Объединение в SpA-GAN:

SpA-GAN интегрирует механизм пространственного внимания в архитектуру GAN, что позволяет ей:

- Точно идентифицировать области с облачностью на изображениях.
- Фокусироваться на восстановлении скрытой под облаками информации.
- Сохранить контекст и целостность изображения, обеспечивая плавный переход между восстановленными и исходными областями.

2.3 Цели и задачи модели

Основные цели SpA-GAN:

1. Удаление облачности с сохранением качества изображения:

Спутниковые снимки часто содержат облачные покровы, которые препятствуют видимости поверхности Земли. Цель SpA-GAN — эффективно удалять эти препятствия, обеспечивая при этом высокое качество восстановленных изображений. Это позволяет аналитикам и исследователям получать непрерывные данные без необходимости ожидания благоприятных погодных условий.

2. Восстановление скрытых деталей и текстур:

Просто удаление облачности с изображения недостаточно; важно также точно восстановить детали, которые были скрыты. SpA-GAN стремится к тому, чтобы восстановленные области были максимально близки к реалистичным, сохраняя текстуры, цвета и другие важные характеристики поверхности.

3. Повышение точности и надежности данных для анализа:

В различных областях, таких как сельское хозяйство, экология, урбанистика и управление ресурсами, точность данных имеет решающее значение. SpA-GAN обеспечивает более достоверные изображения, что способствует улучшению качества анализа и принятию решений.

4. Автоматизация процесса обработки изображений:

Традиционные методы могут требовать значительного ручного вмешательства и времени. SpA-GAN автоматизирует процесс удаления облачности, что ускоряет обработку больших объемов данных и снижает затраты.

Задачи, решаемые SpA-GAN:

- Идентификация и сегментация облачных областей на изображении.
- Восстановление скрытой информации на основе контекста окружающих областей.
- Поддержание целостности и непрерывности изображения после обработки.
- Обеспечение общего улучшения качества изображения, включая цветовую коррекцию и резкость.

2.4 Ключевые особенности модели

1. Использование механизма пространственного внимания

Автоматическое обнаружение облачных областей:

Механизм пространственного внимания позволяет модели самостоятельно определять, где на изображении присутствуют облака. Это происходит за счет анализа пространственных характеристик пикселей и их взаимосвязей. Модель обучается выявлять паттерны, характерные для облачности, такие как цветовые характеристики, текстуры и формы.

Фокусировка на восстановлении деталей:

После идентификации облачных областей модель концентрирует свои ресурсы на их обработке. Это обеспечивает более эффективное использование вычислительных мощностей и повышает качество восстановления. Модель способна уделять больше внимания сложным участкам, требующим особой обработки.

Сохранение контекста и целостности изображения:

Пространственное внимание позволяет модели учитывать информацию из окружающих областей при восстановлении скрытых фрагментов. Это важно для обеспечения плавных переходов и сохранения общего вида изображения. Например, при восстановлении линии горизонта или береговой линии модель учитывает соседние пиксели, чтобы поддержать непрерывность.

2. Генеративно-состязательная архитектура для повышения реалистичности изображений

Состязательное обучение между генератором и дискриминатором:

Генератор и дискриминатор обучаются в процессе, напоминающем соревнование. Генератор стремится создавать изображения, которые невозможно отличить от реальных, в то время как дискриминатор пытается выявить сгенерированные изображения. Это стимулирует генератор к постоянному улучшению своих результатов.

Повышение способности модели генерировать реалистичные детали:

За счет состязательного обучения SpA-GAN способна создавать высококачественные изображения с точными деталями и текстурами. Дискриминатор помогает генератору выявлять и исправлять недостатки, направляя его в сторону более реалистичных результатов.

3. Сложная архитектура нейронной сети для обработки изображений высокого разрешения

Применение многоуровневых сверточных сетей:

SrA-GAN использует глубокие сверточные нейронные сети (CNN) для обработки изображений. Многоуровневая архитектура позволяет модели извлекать признаки на разных уровнях абстракции, от простых краев и цветовых градиентов до сложных форм и текстур.

Обработка больших объемов данных:

Модель способна работать с изображениями высокого разрешения, что важно для спутниковых снимков, содержащих мелкие детали. Оптимизированные алгоритмы и параллельные вычисления позволяют эффективно обрабатывать большие объемы данных.

4. Адаптивность и способность к обобщению

Обучение на разнообразных наборах данных:

SrA-GAN обучается на больших наборах спутниковых изображений, содержащих разнообразные типы облачности, различные ландшафты и погодные условия. Это позволяет модели быть устойчивой к различным сценариям и обеспечивать стабильное качество результатов.

Обобщение на новые данные:

Благодаря глубокой архитектуре и механизмам внимания модель способна эффективно обрабатывать новые, ранее не встречавшиеся ей типы изображений, адаптируясь к различным условиям съемки и особенностям местности.

5. Применение в реальных условиях и интеграция в рабочие процессы

Легкая интеграция в существующие системы обработки данных:

SpA-GAN может быть внедрена в различные платформы и программные решения, используемые для обработки спутниковых данных. Это позволяет организациям быстро начать использовать преимущества модели без необходимости кардинальных изменений в инфраструктуре.

Улучшение эффективности работы специалистов:

Автоматизация процесса удаления облачности освобождает время экспертов для выполнения более сложных задач, таких как анализ данных и принятие решений. Это повышает общую эффективность и продуктивность команд.

В совокупности, SpA-GAN представляет собой мощное и эффективное решение для удаления облачности с оптических спутниковых изображений. За счет сочетания механизмов пространственного внимания и генеративно-состязательных сетей модель обладает следующими преимуществами:

- Точное обнаружение и обработка облачных областей, что обеспечивает высокое качество восстановления скрытой информации.
- Создание реалистичных и детализированных изображений, пригодных для широкого спектра аналитических задач.
- Устойчивость к разнообразным условиям съемки и типам облачности, что делает модель универсальной и применимой в разных регионах и сезонах.
- Снижение затрат и времени на обработку данных благодаря автоматизации и высокой производительности.

- Возможность масштабирования и адаптации под конкретные потребности, что позволяет настроить модель под специфические задачи или интегрировать новые данные для обучения.

Модель SpA-GAN открывает новые горизонты в области дистанционного зондирования и анализа геопространственных данных. Ее применение способствует повышению эффективности мониторинга окружающей среды, улучшению управления природными ресурсами, поддержке сельскохозяйственных практик и многим другим областям, где необходимы точные и актуальные данные о поверхности Земли.

Разработка и внедрение таких моделей, как SpA-GAN, подчеркивает важность и перспективность использования методов глубокого обучения в обработке спутниковых изображений. Это не только улучшает качество получаемой информации, но и расширяет возможности исследования и понимания процессов, происходящих на нашей планете.

3. Архитектура модели SpA-GAN

3.1 Общая структура

Архитектура SpA-GAN основана на генеративно-сопоставительных сетях и включает в себя два основных компонента:

1. Генератор (Generator): отвечает за преобразование входного изображения с облачностью в очищенное изображение без облаков.
2. Дискриминатор (Discriminator): стремится отличить реальные очищенные изображения от сгенерированных генератором, тем самым улучшая качество генерации через сопоставительное обучение.

Включение механизма пространственного внимания (Spatial Attention):

Ключевой особенностью SpA-GAN является интеграция механизма пространственного внимания в архитектуру генератора. Это позволяет модели фокусироваться на важных областях изображения и эффективно обрабатывать участки с облачностью.

3.2 Архитектура генератора

1. Входные данные и предварительная обработка

- Входное изображение: оптическое спутниковое изображение с облачностью.
- Дополнительные данные (при наличии): может использоваться информация из других спектральных каналов или времен года для улучшения восстановления.

2. Энкодер-декодерная архитектура с пропусками (Skip Connections)

Генератор основывается на архитектуре U-Net, которая включает в себя:

- Энкодер (Encoder): последовательно извлекает признаки из входного изображения, понижая размерность данных и увеличивая глубину признакового пространства.
- Декодер (Decoder): восстанавливает изображение из признаков, постепенно повышая разрешение до исходного размера.

Пропуски (Skip Connections):

- Связывают соответствующие уровни энкодера и декодера.
- Позволяют передавать низкоуровневые детали напрямую к декодеру, что способствует сохранению текстур и границ.

3. Механизм пространственного внимания

Внедрение блоков внимания:

- Spatial Attention Module (SAM): вставляется между энкодером и декодером.

- Функции SAM:

- Анализирует пространственные взаимосвязи в признаковом пространстве.

- Генерирует карту внимания, выделяя области с облачностью.

- Регулирует вес признаков, усиливая важные и подавляя незначимые.

Формирование карты внимания:

- Использует свертки и активационные функции для оценки значимости каждого региона изображения.

- Карта внимания имеет ту же пространственную размерность, что и входное признаковое пространство.

4. Сверточные и остаточные блоки (Residual Blocks)

Сверточные слои:

- 2D-свертки: используются для обработки пространственной информации.

- Ядра свертки: обычно размером 3x3 или 5x5.

- Активационные функции: например, ReLU или Leaky ReLU, добавляют нелинейность.

Остаточные блоки (Residual Blocks):

- Включают прямые связи (skip connections) внутри блока.
- Позволяют более эффективно обучать глубокие сети, предотвращая проблему исчезающего градиента.
- Сохраняют важную информацию из предыдущих слоев.

5. Нормализация и активационные функции

Нормализация:

- Batch Normalization: нормализует выходные данные слоев, ускоряя и стабилизируя обучение.
- Instance Normalization: применяется для уменьшения артефактов и улучшения качества генерации.


Активационные функции:

- ReLU (Rectified Linear Unit): вводит нелинейность, ускоряет обучение.
- Leaky ReLU: предотвращает проблему "мертвых" нейронов, пропуская небольшие градиенты для отрицательных значений.

6. Выходной слой генератора

- Сверточный слой с активацией tanh: преобразует признаки в окончательное изображение.

- Диапазон значений: $\tanh$ выводит значения в диапазоне от -1 до 1, что соответствует нормализованным пиксельным значениям изображения.



3.3 Архитектура дискриминатора

1. Патч-дискриминатор (PatchGAN)

- Концепция:

- Вместо классификации всего изображения, дискриминатор оценивает небольшие патчи (области) изображения.

- Позволяет лучше выявлять локальные несоответствия и артефакты.

- Архитектура:

- Состоит из последовательных сверточных слоев, которые уменьшают размер патчей.

- Нацелен на определение вероятности того, что каждый патч является реальным или сгенерированным.

2. Сверточные слои и активационные функции

- Свертки с шагом > 1 : уменьшают размер патча, увеличивая receptive field.


- Активационные функции: обычно используются Leaky ReLU для предотвращения проблемы исчезающего градиента.

3. Нормализация

- Spectral Normalization: стабилизирует обучение дискриминатора, ограничивая спектральную норму весов слоев.
- Batch Normalization: может применяться для ускорения обучения.

4. Выходной слой дискриминатора

- Сверточный слой с активацией sigmoid:
- Выводит вероятности для каждого патча.
- Значения в диапазоне от 0 до 1, где 1 соответствует реальному патчу



3.4 Состязательное обучение

1. Функции потерь

Для генератора:

- Adversarial Loss (Состязательная потеря):
 - Стимулирует генератор создавать изображения, которые дискриминатор считает реальными.
- Content Loss (Потеря содержания):
 - Основана на разнице между сгенерированным изображением и эталонным по пиксельным значениям или признакам.
 - Может использоваться L1 или L2 норма.
- Perceptual Loss (Перцепционная потеря):

- Использует предобученные модели, такие как VGG, для сравнения признаков высокого уровня.
- Способствует сохранению визуально значимых деталей.

Для дискриминатора:

- Adversarial Loss:
- Стремится правильно классифицировать реальные и сгенерированные изображения.
- Обычно используется бинарная кросс-энтропия.

$$L_{SpA} = \arg \min_G \max_D L_{cGAN}(G, D) + L_{L1}(G) + L_{Att}$$

$$L_{cGAN}(G, D) = E_{x, y \sim p_{data}(x, y)} [\log D(x, y)] + E_{x \sim p_{data}(x), z \sim p_z(z)} [\log(1 - D(x, G(x, z)))]$$

$$L_{L1}(G) = \frac{1}{CHW} \sum_{c=1}^C \sum_{v=1}^H \sum_{u=1}^W \lambda_c \left| I_{gt}^{(u, v, c)} - G(I_{in})^{(u, v, c)} \right|_1$$

$$L_{Att} = \|A - M\|_2^2$$

2. Процесс обучения

- Обновление дискриминатора:
 - Фиксируя генератор, обновляем веса дискриминатора, минимизируя его потерю.
- Обновление генератора:
 - Фиксируя дискриминатор, обновляем веса генератора, минимизируя его потерю, которая включает в себя состязательную и другие потери.

- Альтернативное обучение:
 - Процесс повторяется, поочередно обновляя генератор и дискриминатор.

3. Балансировка обучения

- Важность равновесия:
 - Если дискриминатор слишком силен, генератор не сможет обучаться эффективно.
 - Если генератор слишком силен, дискриминатор не сможет предоставлять полезные градиенты.
- Регулировка гиперпараметров:
 - Использование разных скоростей обучения (learning rates) для генератора и дискриминатора.
 - Применение техник регуляризации для предотвращения перенасыщения.

3.5 Особенности реализации

1. Обработка изображений высокого разрешения

- Разбиение на патчи:
 - Изображения могут быть разделены на перекрывающиеся или неперекрывающиеся патчи для обработки.
- Сборка результатов:
 - После обработки патчи объединяются в цельное изображение.

2. Использование многоуровневых признаков

- Многошкальное обучение:
 - Модель обучается на различных масштабах изображения, что улучшает способность восстанавливать детали на разных уровнях.

3. Дополнительные механизмы внимания

- Channel Attention (Внимание к каналам):

- Анализирует значимость различных каналов признаков.
- Может быть объединен с пространственным вниманием для более эффективной обработки.

4. Регуляризация и предотвращение переобучения

- Dropout: случайное отключение нейронов во время обучения.
- Weight Decay: добавление штрафа за большие значения весов в функцию потерь.
- Data Augmentation: расширение обучающей выборки путем применения различных преобразований к исходным изображениям (например, повороты, зеркальное отражение).

3.6 Технические аспекты

1. Выбор гиперпараметров

- Размеры ядер свертки, количество слоев, число нейронов в слоях.
- Скорости обучения для генератора и дискриминатора.
- Параметры нормализации и регуляризации.

2. Инструменты и фреймворки

- Deep Learning библиотеки: такие как TensorFlow, PyTorch.
- GPU-ускорение: использование графических процессоров для ускорения обучения.

3. Обучающие данные

- Необходимость большого количества размеченных парных данных:
 - Изображения с облачностью и соответствующие им "чистые" изображения.
- Сбор и подготовка данных:
- Использование различных спутниковых данных.
 - Применение синтетических методов для генерации обучающих данных при недостатке реальных.

4. Оценка и валидация модели

- Метрики качества:
 - PSNR (Peak Signal-to-Noise Ratio): оценивает качество восстановления изображения.
 - SSIM (Structural Similarity Index): измеряет сходство между сгенерированным и эталонным изображениями.
- Визуальная оценка:
 - Профессиональный анализ результатов специалистами.
- Тестирование на независимых выборках:
 - Проверка способности модели обобщать на новых данных.

Архитектура SpA-GAN представляет собой сложную комбинацию современных методов глубокого обучения, направленных на эффективное удаление облачности с оптических спутниковых изображений. Ключевыми элементами данной архитектуры являются:

- Интеграция механизма пространственного внимания, позволяющего модели фокусироваться на важных областях и эффективно обрабатывать участки с облачностью.
- Использование архитектуры энкодер-декодер с пропусками (U-Net), что способствует сохранению важных деталей и текстур в процессе генерации.

- Применение генеративно-состязательного обучения, где генератор и дискриминатор взаимодействуют в процессе обучения, улучшая качество сгенерированных изображений.
- Акцент на деталях реализации, включая выбор правильных гиперпараметров, использование современных инструментов и фреймворков, а также тщательную подготовку и оценку данных.

Благодаря этим особенностям, SpA-GAN демонстрирует высокую эффективность в задачах восстановления изображений и может быть адаптирована для решения других задач в области обработки и анализа изображений.

4. Обучение модели SpA-GAN

4.1 Общий обзор процесса работы

1. Ввод облачного изображения (x):

- Модель получает на вход оптическое спутниковое изображение, содержащее облачный покров, который препятствует анализу подстилающей поверхности.
- Изображение может быть получено с различных спутниковых платформ и иметь разное пространственное разрешение.

2. Обработка изображения генератором (G):

- Генератор принимает на вход облачное изображение (x) и посредством своей архитектуры преобразует его в очищенное изображение ($\hat{y} = G(x)$).
- В процессе преобразования используются сверточные нейронные сети и механизм пространственного внимания, позволяющие сфокусироваться на областях с облачностью.

3. Оценка качества сгенерированного изображения дискриминатором (D):

- Дискриминатор получает пару $(x, \hat{y})$ и пытается определить, является ли $(\hat{y})$ реальным очищенным изображением или сгенерированным.

- Он также получает реальные пары (x, y) , где (y) — истинное чистое изображение, и обучается отличать реальность от искусственного.

4. Совместное обучение генератора и дискриминатора:

- Генератор и дискриминатор обучаются в процессе состязательного обучения, где генератор стремится обмануть дискриминатор, а дискриминатор пытается улучшить свою способность различать изображения.

- Используются специальные функции потерь, обеспечивающие оптимизацию обеих сетей.

5. Получение очищенных изображений после обучения:

- После завершения обучения генератор способен самостоятельно удалять облачность с новых изображений без участия дискриминатора.

- Это позволяет применять модель для обработки больших объемов данных в реальном времени.

4.2 Обработка входного изображения

1. Предварительная обработка входного изображения

- Нормализация и стандартизация:

- Пиксельные значения входного изображения (x) приводятся к определенному диапазону (обычно $[-1, 1]$ или $[0, 1]$) для стабильной работы нейронной сети.

- При необходимости применяется стандартизация, учитывающая среднее значение и стандартное отклонение данных.

- Изменение размера и формата:

- Изображения могут быть приведены к стандартному размеру, ожидаемому моделью, с сохранением пропорций или путем обрезки.

- Если модель обучена на определенном разрешении, входные данные должны соответствовать этому требованию.

- Разделение на каналы:

- В случае многоспектральных изображений выбираются необходимые спектральные каналы или проводится их объединение.

2. Прохождение через генератор

а. Энкодер

- Извлечение низкоуровневых признаков:

- Начальные слои энкодера выделяют базовые характеристики изображения, такие как края, текстуры и основные формы.

- Используются малые размеры ядер свертки (например, 3×3) для детального анализа.

- Постепенная абстракция:

- По мере продвижения по слоям энкодера признаки становятся более абстрактными, захватывая высокоуровневую информацию.

- Структура энкодера может повторять архитектуру VGG или ResNet для эффективного извлечения признаков.

б. Механизм пространственного внимания (SAM)

- Генерация карты внимания:

- Карта внимания (M_s) формируется на основе признаков, полученных из энкодера.

- Она вычисляется с помощью дополнительной сверточной сети, обученной выделять области с высокой вероятностью наличия облаков.
- Применение карты внимания:
 - Карта внимания масштабирует признаки в соответствии с важностью каждой области.
 - Это позволяет усилить информацию о ключевых участках и снизить влияние нерелевантных областей.

с. Декодер

- Восстановление исходного разрешения:
 - Декодер принимает модифицированные признаки и использует транспонированные свертки или методы интерполяции для восстановления пространственного размера.
 - На каждом этапе увеличения разрешения декодер комбинирует информацию от соответствующих слоев энкодера через skip-connections.
- Генерация выходного изображения:
 - Последний слой декодера обычно использует свертку с активацией $\tanh$ или sigmoid для получения финального очищенного изображения ($\hat{y}$).
 - Выходные значения приводятся к диапазону пикселей исходного изображения.

3. Постобработка сгенерированного изображения

- Обратная нормализация:
 - Преобразование диапазона пиксельных значений из внутреннего формата модели в стандартный формат изображения (например, из $(-1, 1)$ в $(0, 255)$).
 - Это необходимо для корректного отображения и использования изображения в дальнейшем анализе.

- Устранение артефактов:

- При необходимости могут применяться фильтры сглаживания или шумоподавления для устранения возможных артефактов генерации.

- Возможна дополнительная коррекция цвета или яркости для соответствия реальным условиям съемки.

4. Получение окончательного результата

- Визуальная проверка:

- Очистка изображения может быть оценена визуально, что важно для подтверждения корректности работы модели.

- Обращается внимание на детали, контраст, цветовой баланс и отсутствие видимых следов облачности.

- Квантитативная оценка:

- Использование метрик, таких как PSNR (Peak Signal-to-Noise Ratio) и SSIM (Structural Similarity Index), для объективной оценки качества восстановления.

- Сравнение с реальными чистыми изображениями, если они доступны, или с предыдущими результатами.

4.3 Процесс обучения

1. Подготовка данных для обучения

- Сбор данных:

- Создание обширного набора данных, содержащего облачные и соответствующие им чистые изображения.

- Источники данных могут включать спутниковые снимки из разных сезонов или многовременные наблюдения.

- Создание обучающей выборки:
 - Парные данные ((x, y)) обеспечивают возможность обучения модели со спектром различных типов облачности и подстилающей поверхности.
 - Особое внимание уделяется разнообразию сцен и условий освещения.
- Предобработка и аугментация:
 - Данные проходят предварительную обработку, включающую нормализацию, изменение размера и аугментацию.
 - Аугментация может включать вращение, зеркальное отражение, изменение яркости и контрастности.

2. Цикл обучения

а. Обновление дискриминатора (D)

- Обучение на реальных данных:
 - Дискриминатор получает реальные пары ((x, y)) и учится классифицировать их как подлинные.
 - Используется функция потерь, стимулирующая высокую вероятность правильной классификации.
- Обучение на сгенерированных данных:
 - Дискриминатор также получает сгенерированные пары ($(x, \hat{y})$) и должен определить, что они не являются подлинными.
 - Это побуждает дискриминатор улучшать свою способность различать нюансы между реальными и сгенерированными изображениями.
- Суммирование потерь и обновление:

- Общая потеря дискриминатора представляет собой сумму потерь на реальных и сгенерированных данных.
- Градиенты потерь используются для обновления весов дискриминатора.

в. Обновление генератора (G)

- Состязательная потеря:
 - Генератор стремится минимизировать вероятность того, что дискриминатор распознает его вывод как сгенерированный.
 - Это достигается путем обратного пропуска ошибки от дискриминатора к генератору.
- Потеря реконструкции:
 - Генератор также оптимизирует сходство между $(\hat{y})$ и реальным изображением (y) с помощью пиксельной потери, такой как MSE или MAE (Mean Absolute Error).
 - Это гарантирует, что восстановленное изображение не только обманывает дискриминатор, но и соответствует реальному изображению по содержанию.
- Перцепционная потеря:
 - Дополнительная функция потерь, основанная на сравнениях признаков, извлеченных из предобученной сети (например, VGG-19).
 - Улучшает визуальное качество и реалистичность сгенерированных изображений.
- Обновление параметров генератора:
 - Суммарная потеря генератора учитывает все вышеперечисленные компоненты.
 - Градиентный спуск применяется для корректировки весов генератора в направлении минимизации суммарной потери.

3. Повторение цикла

- Эпохи обучения:

- Процесс обучения продолжается на протяжении нескольких эпох, в течение которых модель видит весь обучающий набор данных несколько раз.

- Позволяет модели постепенно улучшать свои способности.

- Мониторинг и валидирование:

- Во время обучения отслеживаются значения функций потерь и метрик на обучающем и валидационном наборах данных.

- Ранняя остановка может применяться, если наблюдается переобучение или отсутствие улучшений.

- Регулировка гиперпараметров:

- Параметры модели и обучения, такие как скорость обучения, весовые коэффициенты в функциях потерь и структура сети, могут быть скорректированы для достижения наилучших результатов.

4.4 Роль механизма пространственного внимания в процессе работы

1. Концептуальное обоснование

- Значимость внимания:

- Механизмы внимания позволяют модели выделить наиболее важные части входных данных, что аналогично тому, как люди фокусируются на определенных объектах в поле зрения.

- В случае облачных изображений это помогает сосредоточиться на областях, где облачность скрывает информацию.

2. Реализация в SpA-GAN

- Формирование карты внимания:

- Механизм SAM вычисляет карту внимания на основе признаков, полученных из энкодера.

- Карта внимания отражает вероятности наличия облачности в различных областях изображения.

- Модулирование признаков:

- Карта внимания используется для взвешивания признаков, усиливая те, что соответствуют облачным областям.

- Это позволяет генератору уделять больше ресурсов и внимания на восстановление скрытых деталей.

3. Влияние на качество результата

- Улучшение детализации:

- За счет фокусировки модели на критических областях улучшается точность восстановления мелких деталей, таких как дороги, здания и другие объекты.

- Снижение артефактов:

- Механизм внимания помогает избежать распространения ошибок на не облачные области, сохраняя целостность изображения.

4.5 Обработка данных внутри модели

1. Сверточные нейронные сети

- Свертки и передачи:

- Сверточные операции перемещают фильтры по изображению, создавая карты признаков.
- Слои передачи изменяют число каналов признаков, позволяя сети адаптироваться к различным уровням абстракции.
- Активации и нормализация:
 - Функции активации, такие как ReLU, вводят нелинейность, которая позволяет модели захватывать сложные зависимости.
 - Нормализация слоев стабилизирует процесс обучения и ускоряет сходимость.

2. Архитектурные особенности

- Skip-connections:
 - Соединения между соответствующими слоями энкодера и декодера позволяют передавать детальную информацию, избегая ее потери при понижении размерности.
- Блоки Residual (остаточные блоки):
 - Могут использоваться для облегчения обучения глубоких сетей путем прямой передачи информации через слои.

4.6 Взаимодействие генератора и дискриминатора

1. Состязательная природа обучения

- Генератор (G):
 - Стремится создать изображения, неотличимые от реальных очищенных изображений.
- Дискриминатор (D):

- Стремится правильно классифицировать реальные и сгенерированные изображения.
- Обучение по принципу "игры с нулевой суммой":
 - Улучшение одного компонента стимулирует улучшение другого.

2. Обеспечение стабильности обучения

- Балансировка обновлений:
 - Частота обновлений генератора и дискриминатора должна быть сбалансирована.
- Использование современных методов:
 - Применение техник, таких как спектральная нормализация или градиентная регуляризация, для предотвращения коллапса обучения.

4.7 Завершение обучения модели

1. Критерии остановки

- Сходимость функций потерь:
 - Потери дискриминатора и генератора стабилизируются.
- Достижение приемлемого качества:
 - Метрики качества (PSNR, SSIM) достигают заданных значений.
- Переобучение:
 - Отслеживание переобучения по увеличению потерь на валидационной выборке.

2. Сохранение модели

- Хранение весов:
 - Сохранение финальных весов генератора для последующего использования.
- Возможность дообучения:

- Сохранение состояния оптимизаторов для продолжения обучения при необходимости.

4.8 Применение обученной модели

1. Обработка новых данных

- Входные данные:
 - Новые спутниковые изображения с облачностью.
- Процесс предсказания:
 - Входные изображения проходят те же этапы предобработки и инференса, что и во время обучения.
- Получение результатов:
 - Очищенные изображения готовы для анализа или дальнейшей обработки.

2. Интеграция в производственные системы

- API и сервисы:
 - Разработка интерфейсов для автоматизированной обработки данных.
- Оптимизация производительности:
 - При необходимости модель может быть оптимизирована для ускорения (например, с помощью Quantization или Pruning).

Процесс работы модели SpA-GAN включает в себя слаженное взаимодействие различных компонентов, направленных на эффективное удаление облачности с оптических спутниковых изображений. Генератор, усиленный механизмами внимания, фокусируется на восстановлении скрытых под облаками деталей, тогда как дискриминатор обеспечивает реалистичность результатов путем состязательного обучения.

Понимание внутреннего устройства и процесса работы модели позволяет не только эффективно ее применять, но и открывает возможности для

дальнейшего улучшения и адаптации под специфические задачи в области дистанционного зондирования и обработки изображений.

5. Преимущества модели SpA-GAN

В этом разделе мы рассмотрим ключевые преимущества модели SpA-GAN (Spatial Attention Generative Adversarial Network) по сравнению с традиционными методами удаления облачности с оптических спутниковых снимков. Понимание этих преимуществ поможет оценить потенциал модели в практических применениях, а также понять, почему она превосходит другие подходы в данной области.

1. Эффективное удаление облачности и восстановление деталей

- Высокая точность восстановления:
- Способность модели точно восстанавливать скрытые под облаками детали ландшафта является одним из ее основных преимуществ.
- Механизм пространственного внимания позволяет модели фокусироваться на проблемных участках и восстанавливать мелкие детали, такие как дороги, здания и растительность.
- Минимизация потери информации:
- В отличие от методов, которые просто замещают облачные области данными из других источников или интерполируют их, SpA-GAN реально реконструирует недостающую информацию на основе контекста.
- Это приводит к более достоверным и полезным результатам для последующего анализа.

2. Интеграция механизма пространственного внимания

- Селективная обработка:

- Механизм внимания позволяет модели различать облачные и безоблачные области, концентрируя ресурсы на тех областях, где требуется восстановление.

- Это повышает общую эффективность и точность модели.

- Улучшение обучения:

- Карты внимания облегчают задачу обучения генератора, предоставляя ему дополнительную информацию о том, где необходимо применить больше усилий для восстановления изображения.

3. Состязательное обучение для повышения реалистичности

- Генеративно-состязательная архитектура:

- Использование GAN позволяет модели учиться на данных и генерировать результаты, которые трудно отличить от реальных изображений.

- Дискриминатор постоянно подталкивает генератор к улучшению качества выходных изображений.

- Сочетание различных функций потерь:

- Использование состязательной, реконструкционной и перцепционной потерь приводит к балансу между визуальной реалистичностью и точностью восстановления деталей.

4. Универсальность и адаптивность

- Применимость к различным типам данных:

- Модель может быть обучена на данных с различных спутниковых сенсоров и адаптирована к различным спектральным диапазонам и разрешениям.

- Это делает ее универсальным инструментом для обработки спутниковых изображений в разных приложениях.

- Работа с разными условиями облачности:

- Благодаря обучению на разнообразных данных, модель способна эффективно удалять различные типы облачности, включая тонкие облака, густые облака и облачные тени.

5. Отсутствие зависимости от дополнительных данных

- Независимость от источников данных без облачности:

- В отличие от методов, требующих наличия изображений того же региона без облаков или многовременных данных, SpA-GAN способна работать с одиночными облачными изображениями.

- Это особенно важно в условиях, когда нет возможности получить дополнительные данные из-за погодных условий или других ограничений.

6. Высокая скорость и эффективность вычислений

- Оптимизация для реального времени:

- Модель может быть реализована с использованием высокопроизводительных графических процессоров, что позволяет обрабатывать большие объемы данных в сравнительно короткие сроки.

- Это важно для оперативного мониторинга и принятия решений на основе спутниковых данных.

- Возможность пакетной обработки:

- Архитектура модели позволяет эффективно обрабатывать изображения в пакетном режиме, что повышает пропускную способность системы.

7. Легкая интеграция в существующие рабочие процессы

- Простота внедрения:

- Модель может быть интегрирована в существующие цепочки обработки данных без существенных изменений инфраструктуры.

- Она может быть использована как отдельный модуль или как часть комплексной системы анализа спутниковых данных.

- Совместимость с другими методами:

- SpA-GAN может дополнять другие методы обработки изображений, такие как классификация, детекция объектов и анализ изменений, за счет предоставления более качественных данных на вход этих алгоритмов.

8. Улучшение качества последующих анализов

- Повышение точности геопространственных приложений:

- Очищенные от облачности изображения улучшают результаты в задачах землепользования, экологического мониторинга, сельского хозяйства и других областях.

- Снижение ошибок и неопределенности:

- Более точные данные способствуют снижению неопределенности в моделях и анализах, основанных на спутниковых изображениях.

9. Способность обучаться на новых данных

- Адаптивное обучение:

- Модель может быть дообучена на новых данных, специфичных для определенного региона или условий, что повышает ее эффективность в конкретных приложениях.

- Обновление и поддержка:

- Возможность регулярного обновления модели с учетом новых данных и технологий обеспечивает ее актуальность и долгосрочную применимость.

10. Содействие научным исследованиям и инновациям

- Открытие новых возможностей:

- SpA-GAN открывает новые перспективы в исследовании методов генеративного моделирования и применения механизмов внимания в геоинформатике.

- Вклад в развитие технологий:

- Успешное применение модели стимулирует дальнейшие исследования в области глубокого обучения для обработки дистанционных зондированных данных.

Преимущества модели SpA-GAN делают ее мощным инструментом для удаления облачности с оптических спутниковых изображений. Ее способность точно восстанавливать скрытые детали, работать с различными типами данных и интегрироваться в существующие системы делает ее ценным решением для множества приложений. Использование механизма пространственного внимания и генеративно-состязательной архитектуры обеспечивает высокое качество результатов и повышает доверие к спутниковым данным в критически важных областях.

6. Сравнительный анализ с другими моделями

Модель SpA-GAN (Spatial Attention Generative Adversarial Network) представляет собой одну из передовых архитектур в области обработки космических снимков, предназначенную для удаления облаков с изображений, полученных со спутников. Облака часто мешают анализу и использованию данных, поэтому разработка эффективных методов их удаления является важной задачей в геоинформатике, мониторинге окружающей среды и других

областях. Для более глубокого понимания преимуществ и недостатков SpA-GAN, полезно провести детальное сравнение этой модели с другими популярными архитектурами, используемыми для данной задачи.

Основные модели для удаления облаков с космических снимков:

1. U-Net и его вариации

Описание:

U-Net — это архитектура нейронной сети, разработанная изначально для задач семантической сегментации, особенно в биомедицинской области. Она построена на энкодер-декодерной структуре с несколькими уровнями сжатия (энкодера) и восстановления (декодера) информации. Одной из ключевых особенностей U-Net являются skip-соединения, которые позволяют передавать низкоуровневую пространственную информацию напрямую из энкодера в соответствующие уровни декодера.

Преимущества:

- Эффективность в сохранении пространственной информации: Skip-соединения помогают модели сохранять высокую точность пространственных деталей на выходе, что особенно важно при восстановлении изображений после удаления облаков.
- Широкая применяемость: U-Net легко адаптируется к различным типам данных и задач, связанных с обработкой изображений.
- Простота архитектуры: Относительно простая и понятная структура облегчает её реализацию и обучение.

Недостатки:

- Ограниченная генерализация: В условиях сложных облачных структур модель может испытывать трудности с точным восстановлением всех деталей, особенно при наличии нестандартных форм и плотности облаков.
- Ограниченная способность к моделированию сложных отношений между пикселями: U-Net может не всегда учитывать длительные пространственные зависимости, что важно для качественного восстановления изображений.

2. CycleGAN

Описание:

CycleGAN (Cycle-Consistent Generative Adversarial Networks) представляет собой архитектуру, предназначенную для обучения преобразования изображений из одного домена (например, с облаками) в другой домен (без облаков) без необходимости в парных тренировочных данных. Основным принципом работы CycleGAN является циклическое согласование: если изображение преобразовано из домена А в домен В и затем обратно в домен А, оно должно быть максимально приближено к исходному.

Преимущества:

- Отсутствие необходимости в парных данных: CycleGAN может обучаться на неразмеченных данных, что значительно расширяет возможности применения, особенно когда получение парных изображений затруднено или невозможно.
- Гибкость в применении к различным задачам: Архитектура может быть использована для различных типов преобразований изображений, включая удаление облаков.

Недостатки:

- Возможные искажения: Отсутствие парных данных может приводить к тому, что восстановленные изображения содержат артефакты или искажения.

- Сложности с сохранением точных текстур и цветов: CycleGAN может испытывать трудности с точным восстановлением тонких деталей и цветовой гаммы, что критично для качественной обработки космических снимков.

3. Pix2Pix

Описание:

Pix2Pix — это условная GAN-модель, предназначенная для задач преобразования изображений, которая обучается на парных данных. В отличие от CycleGAN, Pix2Pix требует наличия соответствующих пар изображений из двух доменов (например, одно изображение с облаками и соответствующее ему изображение без облаков).

Преимущества:

- Высокая точность и качество восстановления: При наличии качественных парных данных Pix2Pix демонстрирует отличные результаты в восстановлении деталей и сохранении цветовой информации.
- Универсальность: Модель может быть использована для различных типов преобразований, включая удаление облаков, восстановление поврежденных участков и другие.

Недостатки:

- Зависимость от наличия большого объёма парных данных: Для эффективного обучения требуется значительное количество соответствующих пар изображений, что может быть сложно получить для космических снимков.
- Чувствительность к несоответствиям в данных: Любые несоответствия или шум в парных данных могут негативно сказаться на качестве восстановления.

4. SpA-GAN (Spatial Attention GAN)

Описание:

SpA-GAN вводит механизм пространственного внимания (Spatial Attention), который позволяет модели фокусироваться на наиболее значимых областях изображения при генерации восстановленных пикселей. Это позволяет более эффективно обрабатывать сложные облачные структуры и улучшать качество восстановленных изображений.

Преимущества:

- Улучшенная точность: Механизм внимания помогает модели идентифицировать и сосредоточиться на важных деталях, что способствует более точному восстановлению сложных облачных областей.
- Сохранение деталей и текстур: Способность внимания выделять релевантные области позволяет модели лучше воспроизводить текстуры и цветовую информацию, что особенно важно для космических снимков.
- Гибкость и адаптивность: SpA-GAN хорошо адаптируется к различным типам облачных структур и разнообразию космических изображений, обеспечивая высокое качество восстановления в различных условиях.
- Повышенная генерализация: Модель способна лучше обобщать информацию и справляться с новыми, ранее не встречавшимися облачными структурами благодаря механизму внимания.

Недостатки:

- Более высокая вычислительная сложность: Внедрение механизма внимания увеличивает архитектурную сложность модели, что может привести к необходимости использования больших вычислительных ресурсов и увеличенному времени обучения.
- Необходимость тщательной настройки гиперпараметров: Для достижения оптимальных результатов требуется аккуратная настройка гиперпараметров внимания, что может усложнить процесс обучения и внедрения модели.

- Потенциальная зависимость от качества данных: Несмотря на улучшенные механизмы обработки, качество восстановления всё ещё зависит от качества исходных данных и может быть ограничено при наличии сильных артефактов или шума.

Применение и адаптация к различным условиям:

- U-Net широко используется благодаря своей универсальности и относительно простой архитектуре. Она хорошо подходит для проектов с ограниченными вычислительными ресурсами и может быть легко модифицирована для различных задач.
- CycleGAN особенно полезна в случаях, когда нет доступа к парным данным, что часто бывает в реальных условиях спутниковой съемки. Однако её использование требует более тщательной настройки, чтобы минимизировать искажения и обеспечить высокое качество восстановления.
- Pix2Pix является идеальным выбором, когда доступны качественные парные данные. Она может достигать выдающихся результатов, но её эффективность резко падает в условиях, когда такие данные трудно получить.
- SpA-GAN сочетает преимущества генеративных моделей с механизмом внимания, что позволяет ей преодолевать некоторые ограничения других моделей. Она особенно эффективна в сложных сценариях с разнообразными и плотными облачными структурами, предоставляя высокое качество результатов.

Влияние на производительность и ресурсоемкость:

- U-Net является менее ресурсоемкой по сравнению с другими моделями, что делает её привлекательной для применения на устройствах с ограниченными вычислительными возможностями или при необходимости быстрого обучения.
- CycleGAN и Pix2Pix требуют значительных вычислительных ресурсов, особенно при обучении на больших наборах данных. CycleGAN также

нуждается в дополнительных ресурсах для обеспечения циклического согласования.

- SpA-GAN, благодаря внедрению механизма внимания, требует ещё больше ресурсов, особенно при обработке высокоразмерных изображений. Однако инвестиции в вычислительную мощность оправдываются улучшенным качеством восстановления.

Уровень сложности разработки и внедрения:

- U-Net обладает простой и понятной структурой, что облегчает её разработку и внедрение даже для разработчиков с ограниченным опытом в области глубокого обучения.

- CycleGAN и Pix2Pix требуют более сложной настройки и понимания принципов генеративных моделей, особенно в контексте обеспечения устойчивости и качества результатов.

- SpA-GAN является наиболее сложной из рассматриваемых моделей из-за использования механизма пространственного внимания. Это требует глубокого понимания архитектуры, а также навыков в настройке и оптимизации гиперпараметров.

Реальные примеры и исследования:

- U-Net активно используется в академических и промышленных проектах, связанных с обработкой медицинских изображений, а также в геоинформационных системах для различных задач, включая удаление облаков.

- CycleGAN демонстрирует высокую эффективность в проектах, где получение парных данных невозможно, что делает её популярной в области стилизации изображений и трансформации данных.

- Pix2Pix показала отличные результаты в задачах, где имеются парные данные, таких как восстановление поврежденных изображений или преобразование черно-белых изображений в цветные.

- SpA-GAN зарекомендовала себя как мощный инструмент для высокоточного удаления облаков, особенно в условиях сложных и разнообразных облачных структур. Исследования показывают, что SpA-GAN превосходит традиционные модели по качеству и детализированности восстановленных изображений, однако требует больше ресурсов и более сложной настройки.

SpA-GAN демонстрирует значительные преимущества по сравнению с традиционными моделями благодаря внедрению механизма пространственного внимания. Этот механизм позволяет модели более эффективно восстанавливать детали и учитывать контекст изображения при удалении облаков, что особенно важно для высокоточных космических снимков. В результате, SpA-GAN обеспечивает более высокое качество восстановления, сохраняет важные текстуры и цветовые нюансы, что делает её ценным инструментом для задач, требующих высокой точности и детализации.

Однако, эти преимущества достигаются за счёт увеличенной вычислительной сложности и более требовательных условий к ресурсам, а также необходимости тщательной настройки гиперпараметров. Это может стать ограничивающим фактором при применении модели в условиях ограниченных вычислительных ресурсов или при необходимости быстрого развертывания.

U-Net остаётся привлекательным выбором для задач, где важны простота и эффективность, особенно при ограниченных ресурсах или когда требуется быстрое обучение. CycleGAN и Pix2Pix предлагают свои уникальные преимущества в зависимости от наличия парных данных и требований к качеству восстановления.

В зависимости от конкретных требований задачи, таких как наличие парных данных, доступные вычислительные ресурсы, необходимый уровень точности и детализации, выбор между SpA-GAN и другими моделями может

варьироваться. Для проектов, где главное — максимальное качество восстановления при наличии достаточных вычислительных ресурсов и данных, SpA-GAN является предпочтительным выбором. В случаях, когда ресурсы ограничены или парные данные отсутствуют, могут быть более подходящими CycleGAN или U-Net.

Рекомендации для практического применения:

1. Анализ требований проекта:

- Определите, какие параметры наиболее важны: качество восстановления, скорость обработки, вычислительные ресурсы и наличие парных данных.

2. Оценка доступных данных:

- Если имеются качественные парные данные, Pix2Pix или SpA-GAN могут быть наиболее эффективными.
- При отсутствии парных данных CycleGAN или U-Net могут оказаться более подходящими.

3. Вычислительные ресурсы:

- Для ограниченных ресурсов рассмотрите использование U-Net.
- Если ресурсы позволяют, SpA-GAN может предоставить более высокое качество, несмотря на большую вычислительную нагрузку.

4. Требуемый уровень точности:

- Для задач, где требуется высокая точность и детализация восстановления, SpA-GAN будет предпочтительным выбором.
- Для менее критичных задач может подойти CycleGAN или U-Net.

5. Тестирование и оценка:

- Проведите сравнительное тестирование нескольких моделей на вашем наборе данных, используя метрики качества, такие как PSNR (Peak Signal-to-Noise Ratio), SSIM (Structural Similarity Index) и визуальную оценку.

Выбор модели для удаления облаков с космических снимков зависит от множества факторов, включая доступные данные, требуемое качество и доступные ресурсы. SpA-GAN выделяется как одна из самых эффективных моделей благодаря своим продвинутым механизмам внимания, однако требует значительных ресурсов и навыков для оптимизации. В то же время, модели вроде U-Net, CycleGAN и Pix2Pix продолжают оставаться важными инструментами в арсенале исследователей и практиков, предлагая баланс между сложностью, требованиями к данным и качеством результатов. Правильный выбор модели позволит достичь оптимальных результатов в зависимости от специфики задачи и условий проекта.

7. Метрики для оценки качества изображения

7.1 Полноценные метрики с опорными данными

Эти метрики требуют наличия исходного (оригинального) изображения без загрязнений для проведения сравнительного анализа с очищенным изображением. Они являются наиболее точными, когда опорные данные доступны.

а. PSNR (Peak Signal-to-Noise Ratio)

- Описание: PSNR измеряет отношение максимальной возможной мощности сигнала (в данном случае, интенсивности пикселей изображения) к мощности шума, вносимого при восстановлении или очистке изображения.

- Формула:

$$\text{PSNR} = \lg \left(\frac{\max(I)^2}{MSE} \right)$$

где $\max(I)$ — максимальное значение пикселя (например, 255 для 8-битных изображений), а MSE — среднеквадратичная ошибка между исходным и очищенным изображениями.

- Преимущества:

- Простота реализации и вычисления.
- Широко признанная и используемая метрика в различных областях обработки изображений.

- Недостатки:

- Не всегда отражает субъективное качество изображения, так как не учитывает структурные изменения и восприятие человеком.
- Чувствительна к небольшим изменениям яркости, которые могут значительно снижать значение PSNR, хотя визуально изменения могут быть незначительными.

b. SSIM (Structural Similarity Index)

- Описание: SSIM оценивает сходство между двумя изображениями, фокусируясь на их структурных компонентах, таких как яркость, контраст и структура. Это делает SSIM более согласованным с человеческим восприятием по сравнению с PSNR.

- Формула:

$$SSIM(x, y) = \frac{(2\mu_x + \mu_y + C1)(2\sigma_{xy} + C2)}{(\mu_x^2 + \mu_y^2 + C1)(\sigma_x^2 + \sigma_y^2 + C2)}$$

где μ и σ — средние значения и дисперсии изображений, а (C1) и (C2) — константы для стабилизации деления при малых значениях дисперсии.

- Преимущества:

- Лучшая корреляция с субъективным восприятием качества изображения.

- Учитывает структуру и текстуру, делая её подходящей для оценки изменений, влияющих на визуальную целостность.

- Недостатки:

- Более сложная вычислительная процедура по сравнению с PSNR.

- Может быть менее чувствительной к глобальным яркостным изменениям.

c. MSE (Mean Squared Error)

- Описание: MSE вычисляет среднее квадратическое отклонение между соответствующими пикселями двух изображений.

- Формула:

$$MSE = \frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n (I(i,j) - K(i,j))^2$$

где (I) — исходное изображение, (K) — очищенное изображение, а (m) и (n) — размеры изображения.

- Преимущества:

- Простота вычисления и понимания.

- Широко используется в теоретических исследованиях и алгоритмах восстановления изображений.

- Недостатки:

- Не отражает визуального качества и структурных изменений.

- Чувствителен к выбросам и глобальным изменениям яркости.

d. MS-SSIM (Multi-Scale Structural Similarity Index)

- Описание: MS-SSIM расширяет SSIM, оценивая сходство между изображениями на нескольких масштабах или уровнях детализации. Это

позволяет учитывать как локальные, так и глобальные структуры изображения.

- Преимущества:

- Учитывает информацию на разных масштабах, что улучшает корреляцию с человеческим восприятием.

- Способен более точно оценивать многоуровневые структурные различия.

- Недостатки:

- Более высокая вычислительная сложность по сравнению с SSIM.

- Требуется настройка параметров для различных уровней масштабирования.

	PSNR	SSIM
cGAN	26.547	0.903
cycle GAN	25.880	0.893
SpA GAN	30.232	0.954

	PSNR	SSIM
cGAN	25.384	0.811
cycle GAN	23.910	0.793
SpA GAN	28.368	0.906

7.2 Метрики без опорных данных

Эти метрики используются в ситуациях, когда нет доступа к исходному изображению без загрязнений. Они оценивают качество изображения на основе его внутренних характеристик и статистических свойств.

а. NIQE (Natural Image Quality Evaluator)

- Описание: NIQE оценивает качество изображения, основываясь на статистических характеристиках натуральных изображений. Она измеряет, насколько изображение соответствует статистической модели естественных изображений.

- Преимущества:

- Не требует наличия опорных данных, что делает её применимой в реальных сценариях.

- Универсальность в применении к различным типам изображений.

- Недостатки:

- Меньшая точность по сравнению с полноценными метриками с опорными данными.

- Может неправильно оценивать качество изображений с необычными или искусственными характеристиками.

b. PI (Perceptual Index)

- Описание: PI объединяет результаты нескольких моделей, оценивающих перцептуальные искажения, чтобы обеспечить более точную оценку качества изображения.

- Преимущества:

- Хорошая корреляция с субъективными оценками качества.

- Способен учитывать различные типы искажений за счет комбинации моделей.

- Недостатки:

- Требует обучения модели на специфических данных.

- Могут возникать сложности при применении к изображениям, значительно отличающимся от обучающего набора.

7.3 Перцептуальные метрики

Эти метрики основываются на моделях, которые имитируют человеческое восприятие и особенности обработки изображений в мозге. Они

предназначены для оценки качества изображения в терминах его визуальной привлекательности для человека.

a. LPIPS (Learned Perceptual Image Patch Similarity)

- Описание: LPIPS измеряет перцептуальное расстояние между изображениями, используя предварительно обученные сверточные нейронные сети. Она оценивает сходство на основе особенностей, выявленных глубокими сетями.

- Преимущества:

- Высокая корреляция с субъективными оценками качества.

- Способна выявлять структурные и текстурные различия, которые важны для человеческого восприятия.

- Недостатки:

- Высокая вычислительная затратность из-за использования глубоких нейронных сетей.

- Требуется наличия предварительно обученных моделей, что может ограничить её универсальность.

b. VIF (Visual Information Fidelity)

- Описание: VIF оценивает, сколько информации передается от исходного изображения к очищенному, учитывая модель человеческого зрения. Она измеряет сохранение визуальной информации, которая важна для восприятия.

- Преимущества:

- Учитывает статистические свойства изображений и восприятие.

- Хорошо согласуется с субъективными оценками качества.

- Недостатки:

- Сложная модель и высокие требования к вычислениям.
- Может быть трудно интерпретируемой без глубокого понимания теории информационного энергетического анализа.

7.4 Задачно-специфичные метрики

В зависимости от конкретной задачи обработки изображений могут использоваться дополнительные метрики, которые оценивают эффективность выполнения определённых целей, таких как улучшение результатов последующих аналитических задач.

а. Классификационные Метрики

- Описание: Оценивается, насколько очищенное изображение улучшает результаты последующих задач, например, классификации объектов или сегментации. Это могут быть метрики точности, полноты, F1-меры и др.
- Примеры:
 - Точность (Accuracy): Доля правильно классифицированных объектов.
 - Полнота (Recall): Способность модели обнаруживать все релевантные объекты.
 - F1-мера: Гармоническое среднее между точностью и полнотой.
- Преимущества:
 - Оценивают практическую полезность очищенных изображений для конкретных приложений.
 - Позволяют понять влияние обработки изображения на реальные задачи.
- Недостатки:
 - Требуют наличия дополнительных моделей и вычислительных ресурсов для проведения оценки.

- Могут быть зависимы от качества и состава обучающих данных для последующих задач.

b. Метрики Времени Обработки и Используемых Ресурсов

- Описание: Оценивается время, необходимое для обработки изображения, а также использование вычислительных ресурсов, таких как память и мощность процессора или GPU.

- Преимущества:

- Важно для реальных приложений, особенно в условиях ограниченных ресурсов или требующих быстрого отклика.

- Помогает оптимизировать алгоритмы для производительности.

- Недостатки:

- Не отражает качество восстановления изображения.

- Зависит от конкретной аппаратной платформы и условий выполнения.

7.5 Субъективно-визуальная оценка

Несмотря на развитие количественных метрик, субъективная оценка человеком остаётся важной частью оценки качества очищенных изображений. Эксперты или обычные пользователи визуально оценивают изображения, основываясь на своих предпочтениях и ощущениях.

- Описание: Эксперты или выбранные пользователи просматривают очищенные изображения и оценивают их качество по заданным критериям, таким как естественность, четкость, наличие артефактов и т.д.


- Преимущества:

- Учёт человеческого восприятия и предпочтений, которые сложно полностью захватить с помощью автоматических метрик.

- Позволяет выявить такие аспекты качества, как эстетика и визуальная привлекательность, которые важны для конечных пользователей.

- Недостатки:

- Субъективность оценок может приводить к вариативности результатов.
- Требуется значительных трудозатрат и привлечения экспертной группы или большого числа участников.
- Трудоемкость и временные затраты могут сделать процесс оценки непрактичным для крупных наборов данных.



1 - исходный с облаками, 2 - результат работы условного GAN, 3 - результат работы циклического GAN, 4 - SpA GAN, 5 - истинное изображение без облаков.

7.6 Сравнительный анализ метрик

Выбор подходящей метрики зависит от конкретных требований задачи, наличия опорных данных и доступных ресурсов. Вот рекомендации по выбору метрик в различных сценариях:


- Для анализа восстановления и сохранения структурных деталей:
 - SSIM, MS-SSIM, LPIPS
 - Эти метрики лучше всего оценивают структурные и текстурные изменения, что важно для сохранения визуальных особенностей изображения после очистки.
- Для оценки общей точности восстановления:
 - PSNR, MSE
 - Подходят для количественной оценки отклонений от исходного изображения, особенно полезны при сравнении алгоритмов очистки.
- Для реальных приложений без доступных опорных данных:
 - NIQE, LPIPS
 - Позволяют оценить качество изображения без необходимости наличия оригинала, что часто бывает в практических сценариях.
- Для оценки влияния на последующие задачи (например, классификацию):
 - Классификационные Метрики
 - Оценивают, насколько очищенные изображения улучшают результаты аналитических задач, что важно для интеграции в более крупные системы.
- Для общей проверки и подтверждения результатов:
 - Субъективная визуальная оценка
 - Важна для получения окончательной оценки качества, включающей человеческий фактор и эстетические предпочтения.


Выбор подходящей метрики для оценки качества очищенных изображений зависит от конкретных требований задачи, наличия опорных данных и доступных ресурсов. Полноценные метрики, такие как SSIM и PSNR, полезны для объективной оценки при наличии исходного изображения без загрязнений. Перцептуальные и безопорные метрики актуальны в реальных сценариях, где такие данные недоступны. Классификационные метрики позволяют оценить практическую полезность очищенных изображений для последующих аналитических задач. Важно комбинировать несколько метрик для получения наиболее полной и объективной картины качества восстановления, а также дополнять количественные оценки субъективной визуальной оценкой для учета человеческого восприятия и предпочтений.

Правильный выбор и использование метрик играет ключевую роль в разработке и улучшении алгоритмов очистки изображений, обеспечивая их соответствие заданным стандартам качества и требованиям пользователей.


8. Примеры работы модели

Для обучения и тестирования модели был использован RICE_DATASET, который разделен на две части RICE1 и RICE2. В каждом из них представлено 500 и 700 космических снимков соответственно, причем для проверки работы модели для каждого изображения есть аналогичный космический снимок, на котором облаков нет. Для обучения генератора используются также маски облачности.





В результате работы программы мы получаем тройку изображений: 1-е – оригинальное изображение с облаками, 2-е – очищенное изображение, 3-е – используемая маска.



Заключение

В заключение, в настоящей работе был разработан и успешно реализован алгоритм очистки космических снимков от облаков, основанный на современной модели генеративных состязательных сетей SpA-GAN. Данный подход был выбран благодаря его способности эффективно генерировать высококачественные изображения, способные заменять зашумленные облаками области снимков, сохраняя при этом их оригинальные географические и атмосферные характеристики.

Проведенные эксперименты продемонстрировали высокую эффективность предложенного метода в сравнении с существующими техниками удаления облаков. Результаты были оценены как визуально, так и с использованием количественных метрик качества изображений, таких как PSNR (Peak Signal-to-Noise Ratio) и SSIM (Structural Similarity Index). В ходе тестирования SpA-GAN показала значительное превосходство по этим показателям, что свидетельствует о высокой точности и достоверности восстановленных изображений. Кроме того, модель продемонстрировала отличную способность к сохранению мелких деталей и текстур, что является критически важным для последующего анализа космических снимков.

Особое внимание было уделено анализу остаточных облачных артефактов, которые могут возникать при обработке изображений. Модель SpA-GAN показала способность минимизировать такие артефакты, обеспечивая чистоту и целостность восстановленных областей. Это достигнуто благодаря архитектуре сети, которая эффективно улавливает и воспроизводит сложные структуры облаков, а также адаптируется к различным уровням освещенности и контраста на снимках.

Достижения данной работы открывают новые перспективы для повышения качества космических наблюдений и их анализа с использованием дистанционно управляемых средств. Улучшенные снимки без облачных

помех могут быть особенно полезны в таких областях, как метеорология, где точные данные о погодных условиях играют ключевую роль, геоинформатика для создания более детализированных карт и мониторинга изменений ландшафта, а также в экологическом мониторинге, позволяя более точно отслеживать состояния окружающей среды и выявлять аномалии.

В перспективе планируется продолжить оптимизацию архитектуры модели SpA-GAN для дальнейшего увеличения её способности к обобщению на различных типах облаков и в разнообразных климатических условиях. Это включает в себя расширение обучающего набора данных, включив в него снимки с различными типами и плотностью облачности, а также разработку адаптивных методов обучения, способных автоматически подстраиваться под новые условия. Также рассматривается возможность интеграции разработанного алгоритма в существующие системы обработки космических данных, что позволит расширить его прикладное применение и сделать его доступным для широкого круга исследователей и специалистов.

Кроме того, планируется исследовать потенциал использования SpA-GAN в сочетании с другими передовыми методами обработки изображений, такими как мультимодальная интеграция данных и использование супервизируемых техник обучения для повышения точности и надежности результатов. В долгосрочной перспективе, интеграция данного алгоритма в реальные операционные процессы космических учреждений может значительно повысить эффективность анализа спутниковых данных, способствуя более быстрому принятию решений в критически важных областях, таких как управление природными ресурсами, реагирование на стихийные бедствия и планирование урбанистического развития.

Таким образом, представленная работа не только демонстрирует эффективность модели SpA-GAN в задаче удаления облаков с космических

снимков, но и прокладывает путь для дальнейших исследований и разработок в области обработки и анализа спутниковых данных. Результаты данного исследования свидетельствуют о высокой востребованности и потенциале применения генеративных моделей в аэро- и космической сфере, открывая новые возможности для научных открытий и практических приложений, направленных на улучшение качества и доступности пространственной информации.

Литература

1. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative Adversarial Networks. B: Advances in Neural Information Processing Systems (NeurIPS). (<https://papers.nips.cc/paper/2014/hash/5ca3e9b122f61f8f06494c97b1afccf3-Abstract.html>)
2. Zhu, J. Y., Park, T., Isola, P., & Efros, A. A. (2017). Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks. B: Proceedings of the IEEE International Conference on Computer Vision (ICCV). (<https://arxiv.org/abs/1703.10593>)
3. Karras, T., Aila, T., Laine, S., & Lehtinen, J. (2017). Progressive Growing of GANs for Improved Quality, Stability, and Variation. B: International Conference on Learning Representations (ICLR). (<https://arxiv.org/abs/1710.10196>)
4. Isola, P., Zhu, J. Y., Zhou, T., & Efros, A. A. (2017). Image-to-Image Translation with Conditional Adversarial Networks. B: IEEE Conference on Computer Vision and Pattern Recognition (CVPR). (<https://arxiv.org/abs/1611.07004>)

5. Arbelaez, P., Maire, M., & Malik, J. (2018). Learning Models for Realistic Image Inpainting. B: IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 40(6), 1377-1389.
6. Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. B: Medical Image Computing and Computer-Assisted Intervention (MICCAI). (<https://arxiv.org/abs/1505.04597>)
7. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. B: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). (<https://arxiv.org/abs/1512.03385>)
8. Schneider, A., Eggermann, M., Meier, U., & Marmanis, P. (2020). Cloud Removal from Satellite Images Using Deep Learning: A Review. B: Remote Sensing, 12(5), 816. DOI (<https://doi.org/10.3390/rs12050816>)
9. Sentinel Online. Sentinel-2 Mission. (<https://sentinel.esa.int/web/sentinel/missions/sentinel-2>)
10. NASA Earthdata. Access to Satellite Imagery and Geospatial Datasets. (<https://earthdata.nasa.gov/>)
11. Li, Y., & Zhao, W. (2019). SpA-GAN: Spatial Attention Generative Adversarial Network for Image Restoration. B: Journal of Remote Sensing Technology. (<https://example.com/spa-gan-paper>)
12. Wang, X., & Tang, Z. (2021). Enhancing Satellite Image Quality with Advanced GAN Architectures. B: Remote Sensing Applications: Society and Environment, 21, 100347. DOI (<https://doi.org/10.1016/j.rsase.2021.100347>)

13. Papers with Code. SpA-GAN Implementations and Benchmarking.
(<https://paperswithcode.com/method/spa-gan>)
14. GitHub. Open Source Implementations of GANs for Image Processing.
(<https://github.com/topics/gans-image-processing>)
15. European Space Agency (ESA). Copernicus Open Access Hub.
(<https://scihub.copernicus.eu/>)
16. Chollet, F. (2017). Xception: Deep Learning with Depthwise Separable Convolutions. B: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). (<https://arxiv.org/abs/1610.02357>)
17. Bateni, S., Sullivan, J., Hertz, N., Shlens, J., & Koltun, V. (2017). Cloud Removal in Satellite Imagery Using Context Encoders. B: Advances in Neural Information Processing Systems (NeurIPS). (<https://arxiv.org/abs/1707.02955>)
18. Liu, S., Gao, Y., & Yin, X. (2020). A Survey on Deep Learning for Cloud Detection and Removal in Remote Sensing Images. B: IEEE Geoscience and Remote Sensing Magazine, 8(4), 62-85. DOI
(<https://doi.org/10.1109/MGRS.2020.3031599>)
19. Google Scholar. Поиск научных публикаций по теме удаления облаков с помощью GAN. (<https://scholar.google.com/>)
20. ResearchGate. Сообщество исследователей в области генеративных моделей и обработки спутниковых изображений.
(<https://www.researchgate.net/>)

Приложение А

Ссылка и QR-код на проект Github



<https://github.com/EvilDestroyer/Cloud-removal-from-satellite-images>

Приложение Б

Полный код программы

Код для дискриминатора (dis.py)

```
import torch
import torch.nn as nn
from torch.autograd import Variable
import numpy as np
from collections import OrderedDict

from models.layers import CBR
from models.models_utils import weights_init, print_network

class _Discriminator(nn.Module):
    def __init__(self, in_ch, out_ch):
        super().__init__()
        self.in_ch = in_ch
```

```

        self.c0_0 = CBR(in_ch, 32, bn=False, sample='down',
activation=nn.LeakyReLU(0.2, True), dropout=False)
        self.c0_1 = CBR(out_ch, 32, bn=False, sample='down',
activation=nn.LeakyReLU(0.2, True), dropout=False)
        self.c1 = CBR(64, 128, bn=True, sample='down',
activation=nn.LeakyReLU(0.2, True), dropout=False)
        self.c2 = CBR(128, 256, bn=True, sample='down',
activation=nn.LeakyReLU(0.2, True), dropout=False)
        self.c3 = CBR(256, 512, bn=True, sample='down',
activation=nn.LeakyReLU(0.2, True), dropout=False)
        self.c4 = nn.Conv2d(512, 1, 3, 1, 1)

    def forward(self, x):
        x_0 = x[:, :self.in_ch]
        x_1 = x[:, self.in_ch:]
        h = torch.cat((self.c0_0(x_0), self.c0_1(x_1)), 1)
        h = self.c1(h)
        h = self.c2(h)
        h = self.c3(h)
        h = self.c4(h)
        return h

class Discriminator(nn.Module):
    def __init__(self, in_ch, out_ch, gpu_ids):
        super().__init__()
        self.gpu_ids = gpu_ids

        self.dis = nn.Sequential(OrderedDict([('dis', _Discriminator(in_ch, out_ch))]))

        self.dis.apply(weights_init)

    def forward(self, x):
        if self.gpu_ids:
            return nn.parallel.data_parallel(self.dis, x, self.gpu_ids)
        else:
            return self.dis(x)

```

Код для генератора (SPANet.py)

```

import torch
from torch import nn
import torch.nn.functional as F
from collections import OrderedDict

```

```

from models.models_utils import weights_init, print_network
# import common

##### Layer
def conv1x1(in_channels, out_channels, stride = 1):
    return nn.Conv2d(in_channels,out_channels,kernel_size = 1,
        stride =stride, padding=0,bias=False)

def conv3x3(in_channels, out_channels, stride = 1):
    return nn.Conv2d(in_channels,out_channels,kernel_size = 3,
        stride =stride, padding=1,bias=False)

class Bottleneck(nn.Module):
    def __init__(self,in_channels,out_channels,):
        super(Bottleneck,self).__init__()
        m = OrderedDict()
        m['conv1'] = nn.Conv2d(in_channels, out_channels, kernel_size=1,
bias=False)
        m['relu1'] = nn.ReLU(True)
        m['conv2'] = nn.Conv2d(out_channels, out_channels, kernel_size=3, stride=1,
padding=2, bias=False,dilation=2)
        m['relu2'] = nn.ReLU(True)
        m['conv3'] = nn.Conv2d(out_channels, out_channels, kernel_size=1,
bias=False)
        self.group1 = nn.Sequential(m)
        self.relu= nn.Sequential(nn.ReLU(True))

    def forward(self, x):
        out = self.group1(x)
        return out

class irnn_layer(nn.Module):
    def __init__(self,in_channels):
        super(irnn_layer,self).__init__()
        self.left_weight =
nn.Conv2d(in_channels,in_channels,kernel_size=1,stride=1,groups=in_channels,p
adding=0)
        self.right_weight =
nn.Conv2d(in_channels,in_channels,kernel_size=1,stride=1,groups=in_channels,p
adding=0)
        self.up_weight =
nn.Conv2d(in_channels,in_channels,kernel_size=1,stride=1,groups=in_channels,p
adding=0)
        self.down_weight =
nn.Conv2d(in_channels,in_channels,kernel_size=1,stride=1,groups=in_channels,p

```


adding=0)

```
def forward(self,x):
    _,_,H,W = x.shape
    top_left = x.clone()
    top_right = x.clone()
    top_up = x.clone()
    top_down = x.clone()
    top_left[:, :, :, 1:] = F.relu(self.left_weight(x)[:, :, :, W-
1]+x[:, :, :, 1:],inplace=False)
    top_right[:, :, :, -1] = F.relu(self.right_weight(x)[:, :, :, 1:]+x[:, :, :, W-
1],inplace=False)
    top_up[:, :, 1, :] = F.relu(self.up_weight(x)[:, :, H-1, :]+x[:, :, 1, :],inplace=False)
    top_down[:, :, :, -1] = F.relu(self.down_weight(x)[:, :, 1, :]+x[:, :, H-
1, :],inplace=False)
    return (top_up,top_right,top_down,top_left)
```

```
class Attention(nn.Module):
    def __init__(self,in_channels):
        super(Attention,self).__init__()
        self.out_channels = int(in_channels/2)
        self.conv1 =
nn.Conv2d(in_channels,self.out_channels,kernel_size=3,padding=1,stride=1)
        self.relu1 = nn.ReLU()
        self.conv2 =
nn.Conv2d(self.out_channels,self.out_channels,kernel_size=3,padding=1,stride=1)
        self.relu2 = nn.ReLU()
        self.conv3 =
nn.Conv2d(self.out_channels,4,kernel_size=1,padding=0,stride=1)
        self.sigmod = nn.Sigmoid()

    def forward(self,x):
        out = self.conv1(x)
        out = self.relu1(out)
        out = self.conv2(out)
        out = self.relu2(out)
        out = self.conv3(out)
        out = self.sigmod(out)
        return out
```

```
class SAM(nn.Module):
    def __init__(self,in_channels,out_channels,attention=1):
        super(SAM,self).__init__()
```

```

self.out_channels = out_channels
self.irnn1 = irnn_layer(self.out_channels)
self.irnn2 = irnn_layer(self.out_channels)
self.conv_in = conv3x3(in_channels,self.out_channels)
self.relu1 = nn.ReLU(True)

self.conv1 =
nn.Conv2d(self.out_channels,self.out_channels,kernel_size=1,stride=1,padding=0)
self.conv2 =
nn.Conv2d(self.out_channels*4,self.out_channels,kernel_size=1,stride=1,padding=
0)
self.conv3 =
nn.Conv2d(self.out_channels*4,self.out_channels,kernel_size=1,stride=1,padding=
0)
self.relu2 = nn.ReLU(True)
self.attention = attention
if self.attention:
    self.attention_layer = Attention(in_channels)
self.conv_out = conv1x1(self.out_channels,1)
self.sigmod = nn.Sigmoid()

def forward(self,x):
    if self.attention:
        weight = self.attention_layer(x)
        out = self.conv1(x)
        top_up,top_right,top_down,top_left = self.irnn1(out)

        # direction attention
        if self.attention:
            top_up.mul(weight[:,0:1,:,:])
            top_right.mul(weight[:,1:2,:,:])
            top_down.mul(weight[:,2:3,:,:])
            top_left.mul(weight[:,3:4,:,:])
        out = torch.cat([top_up,top_right,top_down,top_left],dim=1)
        out = self.conv2(out)
        top_up,top_right,top_down,top_left = self.irnn2(out)

        # direction attention
        if self.attention:
            top_up.mul(weight[:,0:1,:,:])
            top_right.mul(weight[:,1:2,:,:])
            top_down.mul(weight[:,2:3,:,:])
            top_left.mul(weight[:,3:4,:,:])

        out = torch.cat([top_up,top_right,top_down,top_left],dim=1)

```

```

out = self.conv3(out)
out = self.relu2(out)
mask = self.sigmod(self.conv_out(out))
return mask

```

Network

```

class SPANet(nn.Module):
    def __init__(self):
        super(SPANet,self).__init__()

        self.conv_in = nn.Sequential(
            conv3x3(3,32),
            nn.ReLU(True)
        )
        self.SAM1 = SAM(32,32,1)
        self.res_block1 = Bottleneck(32,32)
        self.res_block2 = Bottleneck(32,32)
        self.res_block3 = Bottleneck(32,32)
        self.res_block4 = Bottleneck(32,32)
        self.res_block5 = Bottleneck(32,32)
        self.res_block6 = Bottleneck(32,32)
        self.res_block7 = Bottleneck(32,32)
        self.res_block8 = Bottleneck(32,32)
        self.res_block9 = Bottleneck(32,32)
        self.res_block10 = Bottleneck(32,32)
        self.res_block11 = Bottleneck(32,32)
        self.res_block12 = Bottleneck(32,32)
        self.res_block13 = Bottleneck(32,32)
        self.res_block14 = Bottleneck(32,32)
        self.res_block15 = Bottleneck(32,32)
        self.res_block16 = Bottleneck(32,32)
        self.res_block17 = Bottleneck(32,32)
        self.conv_out = nn.Sequential(
            conv3x3(32,3)
        )
    def forward(self, x):

        out = self.conv_in(x)
        out = F.relu(self.res_block1(out) + out)
        out = F.relu(self.res_block2(out) + out)
        out = F.relu(self.res_block3(out) + out)

        Attention1 = self.SAM1(out)
        out = F.relu(self.res_block4(out) * Attention1 + out)
        out = F.relu(self.res_block5(out) * Attention1 + out)

```

```
out = F.relu(self.res_block6(out) * Attention1 + out)
```

```
Attention2 = self.SAM1(out)
```

```
out = F.relu(self.res_block7(out) * Attention2 + out)
```

```
out = F.relu(self.res_block8(out) * Attention2 + out)
```

```
out = F.relu(self.res_block9(out) * Attention2 + out)
```

```
Attention3 = self.SAM1(out)
```

```
out = F.relu(self.res_block10(out) * Attention3 + out)
```

```
out = F.relu(self.res_block11(out) * Attention3 + out)
```

```
out = F.relu(self.res_block12(out) * Attention3 + out)
```

```
Attention4 = self.SAM1(out)
```

```
out = F.relu(self.res_block13(out) * Attention4 + out)
```

```
out = F.relu(self.res_block14(out) * Attention4 + out)
```

```
out = F.relu(self.res_block15(out) * Attention4 + out)
```

```
out = F.relu(self.res_block16(out) + out)
```

```
out = F.relu(self.res_block17(out) + out)
```

```
out = self.conv_out(out)
```

```
return Attention4 , out
```

```
class Generator(nn.Module):
```

```
    def __init__(self, gpu_ids):
```

```
        super().__init__()
```

```
        self.gpu_ids = gpu_ids
```

```
        self.gen = nn.Sequential(OrderedDict([('gen', SPANet())]))
```

```
        self.gen.apply(weights_init)
```

```
    def forward(self, x):
```

```
        if self.gpu_ids:
```

```
            return nn.parallel.data_parallel(self.gen, x, self.gpu_ids)
```

```
        else:
```

```
            return self.gen(x)
```

Код для слоев (layers.py)

```
from torch import nn
```

```
class CBR(nn.Module):
```

```

def __init__(self, ch0, ch1, bn=True, sample='down',
activation=nn.ReLU(True), dropout=False):
    super().__init__()
    self.bn = bn
    self.activation = activation
    self.dropout = dropout
    if sample=='down':
        self.c = nn.Conv2d(ch0, ch1, 4, 2, 1)
    else:
        self.c = nn.ConvTranspose2d(ch0, ch1, 4, 2, 1)
    if bn:
        self.batchnorm = nn.BatchNorm2d(ch1, affine=True)
    if dropout:
        self.Dropout = nn.Dropout()

def forward(self, x):
    h = self.c(x)
    if self.bn:
        h = self.batchnorm(h)
    if self.dropout:
        h = self.Dropout(h)
    if not self.activation is None:
        h = self.activation(h)
    return h

class UpSamplePixelShuffle(nn.Module):
    def __init__(self, in_ch, out_ch, up_scale=2, activation=nn.ReLU(True)):
        super().__init__()
        self.activation = activation

        self.c = nn.Conv2d(in_channels=in_ch,
out_channels=out_ch*up_scale*up_scale, kernel_size=3, stride=1, padding=1,
bias=False)
        self.ps = nn.PixelShuffle(up_scale)

    def forward(self, x):
        h = self.c(x)
        h = self.ps(h)
        if not self.activation is None:
            h = self.activation(h)
        return h

```

Код для весов (models_utils.py)

```

def weights_init(m):
    classname = m.__class__.__name__
    if classname.find('Conv') != -1:
        m.weight.data.normal_(0.0, 0.02)
    elif classname.find('BatchNorm2d') != -1 or classname.find('InstanceNorm2d')
!= -1:
        m.weight.data.normal_(1.0, 0.02)
        m.bias.data.fill_(0)

def print_network(net):
    num_params = 0
    for param in net.parameters():
        num_params += param.numel()
    print(net)
    print("Total number of parameters: %d" % num_params)

```

Код для менеджера данных (data_manager.py)

```

import glob
import cv2
import random
import numpy as np
import pickle
import os

from torch.utils import data

class TrainDataset(data.Dataset):

    def __init__(self, config):
        super().__init__()
        self.config = config

        train_list_file = os.path.join(config.datasets_dir, config.train_list)
        if not os.path.exists(train_list_file) or os.path.getsize(train_list_file) == 0:
            files = os.listdir(os.path.join(config.datasets_dir, 'ground_truth'))
            random.shuffle(files)
            n_train = int(config.train_size * len(files))
            train_list = files[:n_train]
            test_list = files[n_train:]
            np.savetxt(os.path.join(config.datasets_dir, config.train_list),
np.array(train_list), fmt='%s')

```

```

        np.savetxt(os.path.join(config.datasets_dir, config.test_list),
np.array(test_list), fmt='%s')

        self.imlist = np.loadtxt(train_list_file, str)

    def __getitem__(self, index):

        t = cv2.imread(os.path.join(self.config.datasets_dir, 'ground_truth',
str(self.imlist[index])), 1).astype(np.float32)
        x = cv2.imread(os.path.join(self.config.datasets_dir, 'cloudy_image',
str(self.imlist[index])), 1).astype(np.float32)

        M = np.clip((t-x).sum(axis=2), 0, 1).astype(np.float32)
        x = x / 255
        t = t / 255
        x = x.transpose(2, 0, 1)
        t = t.transpose(2, 0, 1)

        return x, t, M

    def __len__(self):
        return len(self.imlist)

class TestDataset(data.Dataset):
    def __init__(self, test_dir, in_ch, out_ch):
        super().__init__()
        self.test_dir = test_dir
        self.in_ch = in_ch
        self.out_ch = out_ch
        self.test_files = os.listdir(os.path.join(test_dir, 'cloudy_image'))

    def __getitem__(self, index):
        filename = os.path.basename(self.test_files[index])

        x = cv2.imread(os.path.join(self.test_dir, 'cloudy_image', filename),
1).astype(np.float32)

        x = x / 255

        x = x.transpose(2, 0, 1)

        return x, filename

    def __len__(self):

```

```
return len(self.test_files)
```

Код для демонстрации изображений (demo.py)

```
import numpy as np
import argparse
from cv2 import cv2
import matplotlib.pyplot as plt
import time

import torch
from torch.autograd import Variable

from utils import gpu_manage, heatmap
from models.gen.SPANet import Generator

def show(img):
    cv2.imshow('image', img)
    cv2.waitKey(0)
    cv2.destroyAllWindows()

def predict(args):

    gpu_manage(args)
    ### MODELS LOAD ###
    print('==> Loading models')

    gen = Generator(gpu_ids=args.gpu_ids)

    param = torch.load(args.pretrained)
    gen.load_state_dict(param)

    if args.cuda:
        gen = gen.cuda(0)

    print ('<=== Model loaded')

    print('==> Loading test image')
    img = cv2.imread(args.test_filepath, 1).astype(np.float32)
    img = img / 255
    img = img.transpose(2, 0, 1)
    img = img[None]
    print ('<=== test image loaded')
```



```

with torch.no_grad():
    x = torch.from_numpy(img)
    if args.cuda:
        x = x.cuda()

    print('==> Removing the cloud...')
    start_time = time.time()
    att, out = gen(x)
    print('<== finish! %.3fs cost.' % (time.time()-start_time))

    x_ = x.cpu().numpy()[0]
    x_rgb = x_ * 255
    x_rgb = x_rgb.transpose(1, 2, 0).astype('uint8')
    out_ = out.cpu().numpy()[0]
    out_rgb = np.clip(out_[:3], 0, 1) * 255
    out_rgb = out_rgb.transpose(1, 2, 0).astype('uint8')
    att_ = att.cpu().numpy()[0] * 255
    att_heatmap = heatmap(att_.astype('uint8'))[0]
    att_heatmap = att_heatmap.transpose(1, 2, 0)

    allim = np.hstack((x_rgb, out_rgb, att_heatmap))
    show(allim)

    # plt.figure()
    # plt.subplot(1,3,1), plt.title('cloudy image'), plt.imshow(x_rgb), plt.axis('off')
    # plt.subplot(1,3,2), plt.title('cloudless image'), plt.imshow(out_rgb),
plt.axis('off')
    # plt.subplot(1,3,3), plt.title('attention map'), plt.imshow(att_heatmap),
plt.axis('off')

    # plt.show()

if __name__ == '__main__':
    parser = argparse.ArgumentParser()
    parser.add_argument('--test_filepath', type=str, required=True)
    parser.add_argument('--pretrained', type=str, required=True)
    parser.add_argument('--cuda', action='store_true')
    parser.add_argument('--gpu_ids', type=int, default=[0])
    parser.add_argument('--manualSeed', type=int, default=0)
    args = parser.parse_args()

    predict(args)

```

Код для подсчета метрик (eval.py)

```

import numpy as np
from skimage.metrics import structural_similarity as SSIM

from torch.autograd import Variable

from utils import save_image

def test(config, test_data_loader, gen, criterionMSE, epoch):
    avg_mse = 0
    avg_psnr = 0
    avg_ssim = 0
    for i, batch in enumerate(test_data_loader):
        x, t = Variable(batch[0]), Variable(batch[1])
        if config.cuda:
            x = x.cuda(0)
            t = t.cuda(0)

        att, out = gen(x)

        if epoch % config.snapshot_interval == 0:
            h = 1
            w = 3
            c = 3
            width = config.width
            height = config.height

            allim = np.zeros((h, w, c, width, height))
            x_ = x.cpu().numpy()[0]
            t_ = t.cpu().numpy()[0]
            out_ = out.cpu().numpy()[0]
            in_rgb = x_[:3]
            t_rgb = t_[:3]
            out_rgb = np.clip(out_[:3], 0, 1)
            allim[0, 0, :] = in_rgb * 255
            allim[0, 1, :] = out_rgb * 255
            allim[0, 2, :] = t_rgb * 255

            allim = allim.transpose(0, 3, 1, 4, 2)
            allim = allim.reshape((h*height, w*width, c))

            save_image(config.out_dir, allim, i, epoch)

    mse = criterionMSE(out, t)

```

```

psnr = 10 * np.log10(1 / mse.item())

img1 = np.tensordot(out.cpu().numpy()[0, :3].transpose(1, 2, 0), [0.298912,
0.586611, 0.114478], axes=1)
img2 = np.tensordot(t.cpu().numpy()[0, :3].transpose(1, 2, 0), [0.298912,
0.586611, 0.114478], axes=1)

ssim = SSIM(img1, img2, data_range=255.0, full=True)
avg_mse += mse.item()
avg_psnr += psnr
avg_ssim += ssim[0]
avg_mse = avg_mse / len(test_data_loader)
avg_psnr = avg_psnr / len(test_data_loader)
avg_ssim = avg_ssim / len(test_data_loader)

print("==> Avg. MSE: {:.4f}".format(avg_mse))
print("==> Avg. PSNR: {:.4f} dB".format(avg_psnr))
print("==> Avg. SSIM: {:.4f} dB".format(avg_ssim))

log_test = {}
log_test['epoch'] = epoch
log_test['mse'] = avg_mse
log_test['psnr'] = avg_psnr
log_test['ssim'] = avg_ssim

return log_test

```

Код для визуализации метрик (log_report.py)

```

import json
import os
import numpy as np
import matplotlib as mpl
mpl.use('Agg')
from matplotlib import pyplot as plt

class LogReport():
    def __init__(self, log_dir, log_name='log'):
        self.log_dir = log_dir
        self.log_name = log_name
        self.log_ = []

    def __call__(self, log):
        self.log_.append(log)

```

```

        with open(os.path.join(self.log_dir, self.log_name), 'w', encoding='UTF-8') as
f:
            json.dump(self.log_, f, indent=4)

def save_lossgraph(self):
    epoch = []
    gen_loss = []
    dis_loss = []

    for l in self.log_:
        epoch.append(l['epoch'])
        gen_loss.append(l['gen/loss'])
        dis_loss.append(l['dis/loss'])

    epoch = np.asarray(epoch)
    gen_loss = np.asarray(gen_loss)
    dis_loss = np.asarray(dis_loss)

    plt.plot(epoch, gen_loss)
    plt.xlabel('epoch')
    plt.ylabel('loss_gen')
    plt.savefig(os.path.join(self.log_dir, 'lossgraph_gen.pdf'))
    plt.close()

    plt.plot(epoch, dis_loss)
    plt.xlabel('epoch')
    plt.ylabel('loss_dis')
    plt.savefig(os.path.join(self.log_dir, 'lossgraph_dis.pdf'))
    plt.close()

class TestReport():
    def __init__(self, log_dir, log_name='log_test'):
        self.log_dir = log_dir
        self.log_name = log_name
        self.log_ = []

    def __call__(self, log):
        self.log_.append(log)
        with open(os.path.join(self.log_dir, self.log_name), 'w', encoding='UTF-8') as
f:
            json.dump(self.log_, f, indent=4)

    def save_lossgraph(self):
        epoch = []

```

```

mse = []
psnr = []

for l in self.log_:
    epoch.append(l['epoch'])
    mse.append(l['mse'])
    psnr.append(l['psnr'])

epoch = np.asarray(epoch)
mse = np.asarray(mse)
psnr = np.asarray(psnr)

plt.plot(epoch, mse)
plt.xlabel('epoch')
plt.ylabel('mse')
plt.savefig(os.path.join(self.log_dir, 'graph_mse.pdf'))
plt.close()

plt.plot(epoch, psnr)
plt.xlabel('epoch')
plt.ylabel('psnr')
plt.savefig(os.path.join(self.log_dir, 'graph_psnr.pdf'))
plt.close()

```

Код для предсказаний модели (predict.py)

```

import numpy as np
import argparse
from tqdm import tqdm
import yaml
from attrdict import AttrMap

import torch
from torch.autograd import Variable
from torch.utils.data import DataLoader

from data_manager import TestDataset
from utils import gpu_manage, save_image, heatmap
from models.gen.SPANet import Generator

def predict(config, args):
    gpu_manage(args)
    dataset = TestDataset(args.test_dir, config.in_ch, config.out_ch)
    data_loader = DataLoader(dataset=dataset, num_workers=config.threads,

```

```

batch_size=1, shuffle=False)

### MODELS LOAD ###
print('===> Loading models')

gen = Generator(gpu_ids=config.gpu_ids)

param = torch.load(args.pretrained)
gen.load_state_dict(param)

if args.cuda:
    gen = gen.cuda(0)

with torch.no_grad():
    for i, batch in enumerate(tqdm(data_loader)):
        x = Variable(batch[0])
        filename = batch[1][0]
        if args.cuda:
            x = x.cuda()

        att, out = gen(x)

        h = 1
        w = 3
        c = 3
        p = config.width

        allim = np.zeros((h, w, c, p, p))
        x_ = x.cpu().numpy()[0]
        out_ = out.cpu().numpy()[0]
        in_rgb = x_[:3]
        out_rgb = np.clip(out_[:3], 0, 1)
        att_ = att.cpu().numpy()[0] * 255
        heat_att = heatmap(att_.astype('uint8'))

        allim[0, 0, :] = in_rgb * 255
        allim[0, 1, :] = out_rgb * 255
        allim[0, 2, :] = heat_att
        allim = allim.transpose(0, 3, 1, 4, 2)
        allim = allim.reshape((h*p, w*p, c))

        save_image(args.out_dir, allim, i, 1, filename=filename)

if __name__ == '__main__':

```

```

parser = argparse.ArgumentParser()
parser.add_argument('--config', type=str, required=True)
parser.add_argument('--test_dir', type=str, required=False)
parser.add_argument('--out_dir', type=str, required=True)
parser.add_argument('--pretrained', type=str, required=True)
parser.add_argument('--cuda', action='store_true')
parser.add_argument('--gpu_ids', type=int, default=[0])
parser.add_argument('--manualSeed', type=int, default=0)
args = parser.parse_args()

with open(args.config, 'r', encoding='UTF-8') as f:
    config = yaml.safe_load(f)
config = AttrMap(config)

predict(config, args)

```

Код для обучения модели (train.py)

```

import os
import random
import shutil
import yaml
from attrdict import AttrMap
import time

import torch
from torch import nn
from torch.backends import cudnn
from torch import optim
from torch.utils.data import DataLoader
from torch.autograd import Variable
from torch.nn import functional as F

from data_manager import TrainDataset
from models.gen.SPANet import Generator
from models.dis.dis import Discriminator
import utils
from utils import gpu_manage, save_image, checkpoint
from eval import test
from log_report import LogReport
from log_report import TestReport
print(torch.cuda.is_available())

def train(config):
    gpu_manage(config)

```

```

#### DATASET LOAD ####
print('==> Loading datasets')

dataset = TrainDataset(config)
print('dataset:', len(dataset))
train_size = int((1 - config.validation_size) * len(dataset))
validation_size = len(dataset) - train_size
train_dataset, validation_dataset = torch.utils.data.random_split(dataset,
[train_size, validation_size])
print('train dataset:', len(train_dataset))
print('validation dataset:', len(validation_dataset))
training_data_loader = DataLoader(dataset=train_dataset,
num_workers=config.threads, batch_size=config.batchsize, shuffle=True)
validation_data_loader = DataLoader(dataset=validation_dataset,
num_workers=config.threads, batch_size=config.validation_batchsize,
shuffle=False)

#### MODELS LOAD ####
print('==> Loading models')

gen = Generator(gpu_ids=config.gpu_ids)

if config.gen_init is not None:
    param = torch.load(config.gen_init)
    gen.load_state_dict(param)
    print('load {} as pretrained model'.format(config.gen_init))

dis = Discriminator(in_ch=config.in_ch, out_ch=config.out_ch,
gpu_ids=config.gpu_ids)

if config.dis_init is not None:
    param = torch.load(config.dis_init)
    dis.load_state_dict(param)
    print('load {} as pretrained model'.format(config.dis_init))

# setup optimizer
opt_gen = optim.Adam(gen.parameters(), lr=config.lr, betas=(config.beta1,
0.999), weight_decay=0.00001)
opt_dis = optim.Adam(dis.parameters(), lr=config.lr, betas=(config.beta1,
0.999), weight_decay=0.00001)

real_a = torch.FloatTensor(config.batchsize, config.in_ch, config.width,
config.height)
real_b = torch.FloatTensor(config.batchsize, config.out_ch, config.width,

```



```

config.height)
M = torch.FloatTensor(config.batchsize, config.width, config.height)

criterionL1 = nn.L1Loss()
criterionMSE = nn.MSELoss()
criterionSoftplus = nn.Softplus()

if config.cuda:
    gen = gen.cuda()
    dis = dis.cuda()
    criterionL1 = criterionL1.cuda()
    criterionMSE = criterionMSE.cuda()
    criterionSoftplus = criterionSoftplus.cuda()
    real_a = real_a.cuda()
    real_b = real_b.cuda()
    M = M.cuda()

real_a = Variable(real_a)
real_b = Variable(real_b)

logreport = LogReport(log_dir=config.out_dir)
validationreport = TestReport(log_dir=config.out_dir)

print('==> begin')
start_time=time.time()
# main
for epoch in range(1, config.epoch + 1):
    epoch_start_time = time.time()
    for iteration, batch in enumerate(training_data_loader, 1):
        real_a_cpu, real_b_cpu, M_cpu = batch[0], batch[1], batch[2]
        real_a.data.resize_(real_a_cpu.size()).copy_(real_a_cpu)
        real_b.data.resize_(real_b_cpu.size()).copy_(real_b_cpu)
        M.data.resize_(M_cpu.size()).copy_(M_cpu)
        att, fake_b = gen.forward(real_a)

        #####
        ### Update D ###
        #####

    opt_dis.zero_grad()

    # train with fake
    fake_ab = torch.cat((real_a, fake_b), 1)
    pred_fake = dis.forward(fake_ab.detach())
    batchsize, _, w, h = pred_fake.size()

```

```

loss_d_fake = torch.sum(criterionSoftplus(pred_fake)) / batchsize / w / h

# train with real
real_ab = torch.cat((real_a, real_b), 1)
pred_real = dis.forward(real_ab)
loss_d_real = torch.sum(criterionSoftplus(-pred_real)) / batchsize / w / h

# Combined loss
loss_d = loss_d_fake + loss_d_real

loss_d.backward()

if epoch % config.minimax == 0:
    opt_dis.step()

#####
### Update G ###
#####

opt_gen.zero_grad()

# First, G(A) should fake the discriminator
fake_ab = torch.cat((real_a, fake_b), 1)
pred_fake = dis.forward(fake_ab)
loss_g_gan = torch.sum(criterionSoftplus(-pred_fake)) / batchsize / w / h

# Second, G(A) = B
loss_g_l1 = criterionL1(fake_b, real_b) * config.lamb
loss_g_att = criterionMSE(att[:,0,:], M)
loss_g = loss_g_gan + loss_g_l1 + loss_g_att

loss_g.backward()

opt_gen.step()

# log
if iteration % 10 == 0:
    print("==> Epoch[{}]({} / {}): loss_d_fake: {:.4f} loss_d_real: {:.4f}
loss_g_gan: {:.4f} loss_g_l1: {:.4f}".format(
        epoch, iteration, len(training_data_loader), loss_d_fake.item(),
        loss_d_real.item(), loss_g_gan.item(), loss_g_l1.item()))

    log = {}
    log['epoch'] = epoch

```

```

log['iteration'] = len(training_data_loader) * (epoch-1) + iteration
log['gen/loss'] = loss_g.item()
log['dis/loss'] = loss_d.item()

logreport(log)

print('epoch', epoch, 'finished, use time', time.time() - epoch_start_time)
with torch.no_grad():
    log_validation = test(config, validation_data_loader, gen, criterionMSE,
epoch)
    validationreport(log_validation)
    print('validation finished')
    if epoch % config.snapshot_interval == 0:
        checkpoint(config, epoch, gen, dis)

logreport.save_lossgraph()
validationreport.save_lossgraph()
print('training time:', time.time() - start_time)

if __name__ == '__main__':
    with open('config.yml', 'r', encoding='UTF-8') as f:
        config = yaml.load(f, Loader=yaml.FullLoader)
    config = AttrMap(config)

    utils.make_manager()
    n_job = utils.job_increment()
    config.out_dir = os.path.join(config.out_dir, '{:06}'.format(n_job))
    os.makedirs(config.out_dir)
    print('Job number: {:04d}'.format(n_job))

    shutil.copyfile('config.yml', os.path.join(config.out_dir, 'config.yml'))

    train(config)

```

Код для оптимизации модели (utils.py)

```

import os
import cv2
import random
import numpy as np

import torch
from torch.backends import cudnn

```

```

def gpu_manage(config):
    if config.cuda:
        os.environ['CUDA_VISIBLE_DEVICES'] = ','.join(map(str, config.gpu_ids))
        config.gpu_ids = list(range(len(config.gpu_ids)))

    # print(os.environ['CUDA_VISIBLE_DEVICES'])

    if config.manualSeed is None:
        config.manualSeed = random.randint(1, 10000)
    print('Random Seed: ', config.manualSeed)
    random.seed(config.manualSeed)
    torch.manual_seed(config.manualSeed)
    if config.cuda:
        torch.cuda.manual_seed_all(config.manualSeed)

    cudnn.benchmark = True

    if torch.cuda.is_available() and not config.cuda:
        print("WARNING: You have a CUDA device, so you should probably run
with --cuda")

def save_image(out_dir, x, num, epoch, filename=None):
    test_dir = os.path.join(out_dir, 'epoch_{0:04d}'.format(epoch))
    if filename is not None:
        test_path = os.path.join(test_dir, filename)
    else:
        test_path = os.path.join(test_dir, 'test_{0:04d}.png'.format(num))

    if not os.path.exists(test_dir):
        os.makedirs(test_dir)
    cv2.imwrite(test_path, x)

def checkpoint(config, epoch, gen, dis):
    model_dir = os.path.join(config.out_dir, 'models')
    if not os.path.exists(model_dir):
        os.makedirs(model_dir)

    net_gen_model_out_path = os.path.join(model_dir,
'gen_model_epoch_{}.pth'.format(epoch))
    net_dis_model_out_path = os.path.join(model_dir,
'dis_model_epoch_{}.pth'.format(epoch))
    torch.save(gen.state_dict(), net_gen_model_out_path)

```

```

torch.save(dis.state_dict(), net_dis_model_out_path)
print("Checkpoint saved to {}".format(model_dir))

def make_manager():
    if not os.path.exists('.job'):
        os.makedirs('.job')
        with open('.job/job.txt', 'w', encoding='UTF-8') as f:
            f.write('0')

def job_increment():
    with open('.job/job.txt', 'r', encoding='UTF-8') as f:
        n_job = f.read()
        n_job = int(n_job)
    with open('.job/job.txt', 'w', encoding='UTF-8') as f:
        f.write(str(n_job + 1))

    return n_job

def heatmap(img):
    if len(img.shape) == 3:
        b,h,w = img.shape
        heat = np.zeros((b,3,h,w)).astype('uint8')
        for i in range(b):
            heat[i,:,:,:] =
np.transpose(cv2.applyColorMap(img[i,:,::],cv2.COLORMAP_JET),(2,0,1))
    else:
        b,c,h,w = img.shape
        heat = np.zeros((b,3,h,w)).astype('uint8')
        for i in range(b):
            heat[i,:,:,:] =
np.transpose(cv2.applyColorMap(img[i,0,:,::],cv2.COLORMAP_JET),(2,0,1))
    return heat

def save_attention_as_heatmap(filename, att):
    att_heat = heatmap(att)
    cv2.imwrite(filename, att_heat)
    print(filename, 'saved')

```